基于 key-value 的 NoSQL 数据存储系统的设计与实现

软件工程　罗晨　　指导教师　穆斌

【摘要】 随着大数据时代的来临，传统的关系数据库开始难以适应大规模数据存储以及高并发访问的应用需求。人们开始逐渐探索采用非关系的方式管理数据，NoSQL 数据库也应运而生。NoSQL 数据库通常具有模型简单、易于扩展、高可用、高并发等特性，因而被许多互联网公司广为使用。本文在此基础上设计并实现了一种基于键值的分布式数据存储系统 kvstore。kvstore 基于键值数据模型，采用主从式架构，并具有负载均衡、高度容错、故障恢复等特点。

【关键词】 NoSQL 数据库 分布式存储 CAP 理论 键值存储

【Abstract】 With the coming of age of big data, the traditional relational database is becoming problematic and difficult to meet the requirements of large scale data storage and high concurrent data access. People commenced trying to manage large scale data with non-relational model, and nosql data storage system also come into being in such background. On the basis of previous work, this paper designed and implemented a key-value based distributed data storage system, called kvstore. Kvstore based on key-value model to manage data sets, and utilize the master-slave architecture to coordinate cluster servers. The key features of kvstore are load balancing, high fault tolerance and automatic failure recovery.

【Keywords】 NoSQL, Database, Distributed Storage, CAP, Key-Value Storage

目录

1 引言

1.1 课题背景

随着互联网的发展， 互联网应用的用户数量以及数据规模开始呈现爆炸式的增长。对于此类新兴的互联网应用，其特点通常为高并发访问、海量数据存储以及相对弱的事务操作。在这种大数据时代的背景下，单机系统早已不能满足软件系统的需求，因此人们提出了许多扩展方案以提高系统性能。但传统的数据库由于模型复杂、提供 ACID 属性的事务，很难进行分布式扩展，因而开始不能满足日益增长的大数据存储需求。在这种背景下，NoSQL 数据库应运而生。NoSQL 数据库具有模型简单、易于扩展等特点，受到开发人员的青睐。目前业界许多 IT 公司都实现了自己的 NoSQL 数据存储系统，并搭建了基于数以千计机器的集群，展示了 NoSQL 数据存储系统的强大魅力。

本课题借鉴了目前业界主流的 NoSQL 数据存储系统的实现方案，并在前人工作的基础上，设计并实现了名为“kvstore”的基于键值的分布式数据存储系统原型。

1.2 研究目标

本课题最终应设计并实现分布式的键值数据存储系统的原型，并应支持如下几大功能：键值操作、内存与持久化两种存储方式、负载均衡、故障自动恢复、多语言客户端等。系统完成之后，应进行相应的功能测试和性能测试，以证明系统的正确性以及高可用性。

1.3 论文结构

本文第 2 章介绍了分布式数据存储系统所涉及的相关概念及理论。之后的第 3、4 章介绍了系统的实现方案，第 3 章大致介绍了系统的总体架构以及各组件的功能，而第 4 章则介绍了系统功能的实现算法与过程。第 5 章给出了系统的性能数据，第 6 章则通过实例介绍了本系统的使用场景。最后第 7 和 8 章分别介绍了本课题的相关工作以及结论和展望。

2 相关概念

2.1 数据存储系统

数据存储系统也可被称作数据库管理系统，由一个互相关联的数据的集合和一组用以访问这些数据的程序组成[1] 。数据库技术最初产生于 20 世纪 60 年代中期，随着计算机管理数据的规模越来越大，应用越来越广泛。数据库技术也在不断地发展和提高。尤其在 1970 年 IBM 的研究员发表的“A Relational Model of Data for Large Shared Data Banks”[2] 奠定了现代关系数据库的基础。

关系数据库是创建在关系模型基础上的数据库，借助于集合代数等数学概念和方法来处理数据库中的数据。关系数据库提供完整的关系操作（增、删、改、查等），完整性约束（实体完整性、参照完整性和用户定义完整性）以及关系数据语言 SQL。关系数据库中的数据通

过关系（表）来组成，结构清晰，并且功能完备，因此被广为使用。目前比较流行的关系数据库有 Oracle，MySQL，微软的 SQLSERVER 等。

除了关系数据库之外，目前业界比较流行还有对象数据库。对象数据库是人们为了适配当前面向对象语言（如 C++，Java）而尝试开发的一种数据库。面向对象语言可以直接操作数据库中的对象，而无需进行繁琐的转换。比较有代表性的对象数据库有 Versant 公司的 Versant 以及 db4o 数据库，其主要运用在电信、金融等领域。但由于对象数据库的诞生时间较晚，以及缺少形式化的数学基础而导致的查询上的弱势，对象数据库并没有广泛的流行起来。

由于关系数据库在业界所占非常大的比重，因此本论文中主要考虑关系数据库，除了特殊的说明之外，下文中的“数据库”也代指的是关系数据库。

2.2 传统数据库瓶颈

由于关系数据库对数据的存储与操作提供了强大的支持，人们也因此普遍采用关系数据库作为应用的数据存储系统。但随着互联网的发展和互联网用户的增多导致了数据规模的急剧膨胀以及高并发的数据访问，例如 Google、Facebook 此类网站，传统的关系数据库在这种环境下开始逐渐成为应用的瓶颈之一：

(1) 随着数据集的增大和高并发的访问，单机数据库难以处理大规模的数据存储与访问；

(2) 关系数据库通常为了提供数据的强一致性约束和 ACID 属性的事务，会在并发的数据访问时对数据进行加锁，因此限制了并发能力；

(3) 同样由于强一致性的保证，关系数据库难以实现分布式。虽然可以通过 two-phase commit[3] 等技术来实现分布式事务，但通常会涉及集群中的所有机器，同样限制了集群的规模；

(4) 关系数据库提供存储过程以实现数据操作的业务逻辑，但随着 SOA 架构的流行，人们逐渐开始将数据操作与数据存储解耦，即数据操作放在业务层以 web 服务或远程调用的方式提供，而数据库中只负责存储数据。

虽然关系数据库比较难以实现分布式，但目前仍有一些公司通过放松数据一致性的要求以及放弃关系数据库中的某些特性（如表连接查询）实现了关系数据库的分布式集群，并得到了较好的效果。以此为代表的是 eBay 所采用的以分库分表的方式[4] 构建数据库集群。通过对数据的主键或某些业务属性进行分组，可以将数据分配到不同的表或不同的数据库中。但需要额外的路由程序或查询解释器将数据映射到相应的表或数据库中，同时也失去了数据的强一致性保证。

2.3 NoSQL 数据库

NoSQL 通常也是 Not Only SQL 的缩写，是对不同于传统的关系数据库的数据库管理系统的统称。NoSQL 数据库与传统的关系数据库在很多方面上都有区别，但最重要的特点是 NoSQL 数据库不使用关系数据模型，因而也更加灵活，并具有良好的水平扩展性。

目前 NoSQL 数据库通常包括以下几类[5] ：

(1) 键-值存储：系统根据用户定义的键来存储并索引对应的值。键-值存储系统就像一个哈希表，但是通常提供了额外的功能，例如数据副本，版本控制，加锁，事务，键排序等。键-值存储系统的代表有 Redis(http://redis.io)，Amazon 公司研发的 Dynamo[6] 等。

(2) 文档存储：系统存储定义好的文档，并提供索引和简单的检索机制。与键值存储不同的是，这类系统通常提供二级索引，多种类型的文档以及嵌套文档。文档存储系统的代表有 MongoDB（http://www.mongodb.org/）。

(3) 可扩展的记录存储：系统存储可被垂直分区以及水平分布在不同节点上的可扩展的记录。基本的数据模型通常为行和列，行通过唯一的键指定，而列中通常包含若干预定义好的组以及任意多的属性。可扩展的记录存储系统的代表有 Google 公司研发的 BigTable[7] ，Cassandra[8] 等。

以上几种 NoSQL 数据库都包含一些相似的特征，例如数据的无结构或弱结构性，提供弱一致性或最终一致性[9] 的保证，易于水平扩展，很少提供事务支持等。而通常的互联网应用如社交网站、论坛、邮箱等，业务逻辑较为简单，对数据的一致性要求不是太高，并且通常具有大数据、高并发等特性，因此比较适合采用 NoSQL 数据库作为数据存储系统。而与此同时，NoSQL 数据库也在这些大型的互联网公司的推动以及大数据的背景下不断发展，与关系数据库进行更好的互补。

2.4 系统扩展性

随着大数据时代的来临，传统的单机数据库模式早已不能适应日益增长的数据规模和高并发的访问。对于数据库系统的扩展方式，通常有如下两种不同的方案。

2.4.1垂直扩展

垂直扩展即对一个计算实体增加资源而提高计算实体的性能，例如使用更多核的 CPU，添加更多的内存和硬盘等。垂直扩展的优点是简单方便，而且软件系统无需对代码进行修改。目前市场上许多服务器厂商如 Dell、IBM、联想等都提供有超高性能的服务器产品。然而垂直扩展的缺点也是显而易见，首先超高性能服务器的价格远远高于普通机器，其次服务器很难无限制的扩展，容易达到瓶颈，并且性能越高，进一步扩展的开销也就越大，最后单机的失效会导致整个系统的瘫痪。因此垂直扩展的架构方案并没有被广泛的采用。

2.4.2水平扩展

水平扩展也被称作横向扩展。与垂直扩展相反，水平扩展将多个计算实体通过特定的软硬件连接成为一个逻辑的实体以提供更强大的计算能力。水平扩展通常采用性能普通的服务器甚至 PC 机，通过特定的分布式算法将任务分配到不同的机器上，以获得强大的计算能力。例如 Google 的 BigTable[7] 存储系统就已经实现了由上千台机器组成的集群。水平扩展方案价格低廉，使用普通的机器便可获得强大的计算能力，而且集群的总体性能也不受单台机器性能的限制，因而也受到许多 IT 公司的青睐。

然而水平扩展在实施上通常也比垂直扩展更加复杂：

(1) 数据存储系统的水平扩展需要软件层面的支持。例如 eBay 公司的分库分表方案[4] ，需要专门的路由程序的支持，以将数据根据主键或特定的业务属性分配到对应的机器中。

(2) 集群具有较高的维护难度和成本。随着机器数量的增加，集群的维护成本也相应的增加，并且需要自动化工具的支持以实现日常的维护工作。

(3) 分布式集群为系统提出了额外的问题和复杂性，例如网络分区问题，节点失效问题，节点间协调问题等等，都需要软件系统予以额外的考虑。

垂直扩展与水平扩展具有各自的优缺点，二者适应的场景也有所不同。垂直扩展的简单

方便比较受非 IT 企业的青睐，如电信、金融、能源等领域的公司，并且垂直扩展带来的性能提升也可基本满足其业务需求。而水平扩展由于比较复杂，目前只有较大的 IT 公司如 Google、Facebook、Amazon 等才有能力自主研发数据存储系统，并搭建大规模的集群。本论文中所实现的系统基于横向扩展，将多服务器搭建成统一的集群，以提供数据存储服务。

2.5 CAP 理论

2000 年，加州大学伯克利分校的 Eric Brewer 教授在 2000 年的分布式原则研讨会上提出了著名的 CAP 理论，即对于一个分布式系统来说，不可能同时满足以下三点：

(1) 一致性（Consistency），即所有节点在同一时间有相同的数据；

(2) 可用性（Availability），保证每个请求不管成功或者失败都有响应；

(3) 分区容忍性（Partition Tolerance），系统中任意信息的丢失或失败不会影响系统的继续运作。[11]

而 CAP 理论的正确性也在 2002 年麻省理工学院的 Seth Gilbert 等人的“Brewer's conjecture and the feasibility of consistent, available, partition-tolerant web services”[12] 论文中被证明。

由于分区容忍性是分布式系统的基础，因此人们通常会在一致性和可用性之间进行取舍，或对二者进行平衡。具有一致性与分区容忍性（CP）的代表系统有 Google 公司的 BigTable[13] [7] 系统，其通过 Google File System[13] 实现了较高的数据一致性。而 Amazon 的 Dynamo[6] 系统则通过版本号机制和数据多备份等实现了高可用性，然而应用程序则需要解决有可能读取不到最新数据的问题。而另一类系统如 Cassandra（http://cassandra.apache.org/）则允许用户配置成功写操作的最小节点数（W）、成功读操作的最小节点数（R）和副本节点的数量（N）来调整系统的一致性和可用性。当 W+R 越大，则一致性越高，可用性越低，反之亦然。

3 系统架构

3.1 架构概览

3.1.1 总体架构

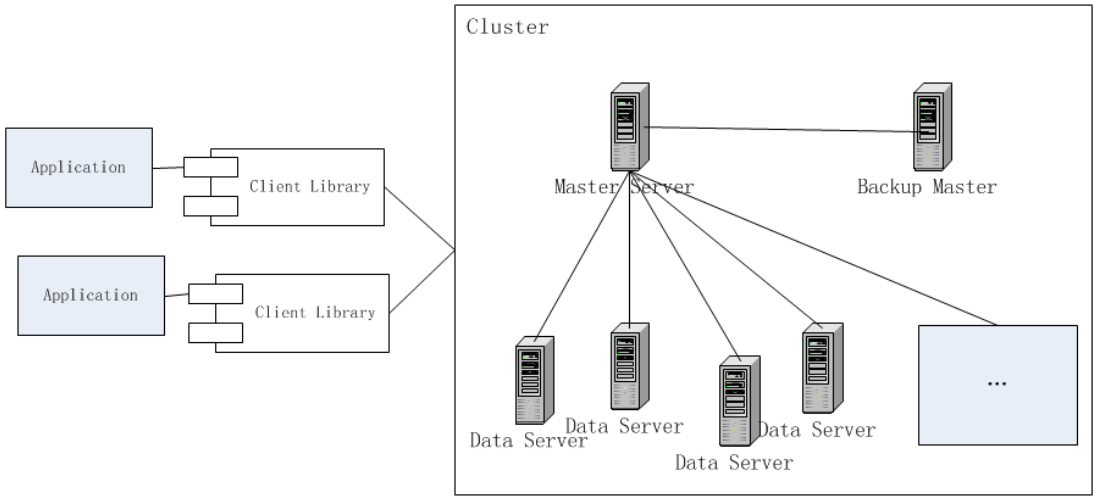

图表 3-1 系统总体架构图

图表 3-1 为系统的总体架构图。系统集群采用 Master-Slave 架构，并提供 Backup Master 以避免单点失效。应用程序通过系统提供的相应语言版本的客户端库程序访问集群，以使用系统提供的数据存储服务。

(1) 主服务器（Master Server）

主服务器是系统中的“管理者”，负责监听集群状态（例如数据服务器的加入与移除），定期收集各个数据服务器的状态信息，并对集群数据服务器进行负载均衡操作。此外，主服务还会响应客户端的 Region 表请求，返回目前集群中的 Region 表。集群只能同时允许一个主服务器存在。主服务器将在章节 3.4 主服务器中详细介绍。

(2) 备份主服务器

为了避免主服务器的单点失效问题，集群中通常还会有备份主服务器。备份主服务器在功能上与主服务器完全相同，但是所有的主服务器在启动时都会参与到领导选举算法中，被选作领导的服务器会成为主服务器，而其他的服务器都会成为备份主服务器，等待下一次领导选举算法的执行。

(3) 数据服务器（Data Server）

数据服务器负责存储系统中的键值对数据。每个数据服务器会被主服务器分配若干个 Region，数据服务器会负责这些 Region 范围内的键值对的操作。数据服务器提供内存和持久化两种存储引擎，内存存储引擎完全使用内存存储，但在内存容量满之后会置换出某些键值对，因而适合用作缓存系统；而持久化存储引擎则使用文件的方式保证数据的持久性存储。数据服务器将在章节 3.5 数据服务器中详细介绍。

(4) 客户端程序库（Client Library）

客户端程序库是应用程序访问本系统数据存储服务的桥梁。客户端程序库主要封装了键路由、网络连接管理等工作。开发人员只需指定主服务器的地址，便可通过 get、set 等操作访问本系统，而无需繁琐的初始化、连接建立与释放等工作。理论上系统支持任意语言的客户端访问，只要客户端按照网络消息协议的规范与主服务器以及数据服务器交互即可。目前系

统提供了Java和C#两个版本的客户端程序库。客户端程序库将在章节3.6客户端中详细介绍。

(5) 应用程序（Application）

应用程序是系统的最终用户，通过系统提供的客户端库程序访问集群以使用系统的数据存储服务。目前 Java 和 C#的应用程序可直接使用系统提供的客户端库，而其他语言的应用则需要按照系统的网络消息协议，开发对应的客户端库程序。应用程序可自己解释键值的含义，例如序列化的对象、文档等，同时也可根据不同的需求定制系统的功能，如用作缓存系统、持久存储系统等。

3.1.2设计风格

kvstore 作为系统级应用和框架级应用，应具有较高的性能、较好的可扩展性、可维护性以及提供简单易用的 API。为达到这些目标，本系统的设计与编码遵循如下几点原则和风格：

(1) KISS 原则

KISS 是 Keep it simple stupid 的缩写，即应尽可能的将系统设计的简单易用。kvstore 系统实现过程中尽可能的将复杂的操作拆分并简化，通过简单来提高性能，提高可靠性。同时系统提供的接口也应保持简洁，方便开发人员学习和使用。

(2) 面向接口编程

面向接口编程即系统的模块与模块之间通过接口进行依赖，而不是直接依赖于实现类。面向接口编程有益于系统中模块间的解耦，增加系统的灵活性和可扩展性。在 kvstore 系统中，所有可能发生变化的实现都被抽象为接口，并通过接口进行调用。因而当需要更换某个接口的实现类时，可以尽可能的避免其他模块的修改。

(3) 事件驱动

为提高扩展性，系统在许多操作中都提供了事件点，并允许调用者注册监听器进行回调。通过事件驱动机制，可以灵活的向已有实现中添加功能。例如，系统在每个 get、set 等操作后都提供了事件点，可以以此添加日志监听器、统计监听器等功能。

(4) 使用设计模式

设计模式是前人对已有设计问题的总结，也是最佳实践。通过使用设计模式，可以帮助实现高内聚低耦合的目标，提高系统的灵活性、可扩展性和可维护性；同时由于大多数开发人员对设计模式都有所了解，因此通过遵循已有的设计模式，也可让开发人员更快的使用及开发本系统。本系统中广泛用到了工厂模式、代理模式、策略模式、装饰模式、迭代器模式等。

(5) 可配置性

为保证灵活性，系统将各种参数都作为可配置参数。用户可在配置文件以键值对的形式指定参数名和值。可配置性允许系统满足不同的应用需求，例如作为缓存系统或持久性存储系统，作为单机系统或分布式系统。同时可配置性也允许用户根据不同的环境对系统进行不同的优化，例如对不同配置的机器设置大小不同的缓存，以逐渐在系统的运维中找到最优的配置方案。

3.2 系统依赖

kvstore 作为分布式数据存储系统，需要数据的持久化存储、副本、分布式协调、网络通信等基础功能。以下系统或框架作为 kvstore 的基础设施，为 kvstore 的实现提供了基础。

3.2.1 分布式文件系统

分布式文件系统是建立在网络之上的文件系统，即通过软件的方式，将多台服务器的文件系统集中成统一的文件系统，为用户提供文件的存储与访问服务，具有高度的透明性。

本系统采用 HDFS（Hadoop Distributed File System）作为文件系统，以存储操作日志文件和数据文件。HDFS 是 Hadoop 项目的一部分，也是 Google File System[10] 的开源 Java 版本实现。HDFS 具有如下几大特性：

(1) 适于利用普通服务器搭建分布式存储集群，并且具有容错性和易于扩展性。
(2) 具有高度配置性，可通过配置系统参数如文件块大小、副本数量等适应不同的需求。
(3) 由 Java 编写，可支持所有主流平台。
(4) 内置了 web 服务器，可以方便检查集群的状态。
(5) 支持文件的负载均衡，尽可能的将文件均匀分布到每个节点上。
(6) 提供类似 Java IO 的流式 IO 接口，简单易用。

由于 HDFS 通过文件的副本机制提供了数据的容错性，因此本系统中将通过在 HDFS 中存储操作日志和数据文件，即利用 HDFS 自身提供的容错性机制，来保障数据的可靠性。

另外由于 Apache 官方提供的发行版本中并未提供 HDFS 单独包，而是作为 Hadoop 系统的一部分进行发行。因此为减少本系统的依赖，作者基于 Hadoop r1.0.4 版本的源码，将其中的 HDFS 部分单独打包以供本系统使用。

3.2.2 分布式协调系统

本系统选用 ZooKeeper 作为分布式协调系统。ZooKeeper(http://zookeeper.apache.org/)是 Hadoop 的子项目，也是 Google Chubby[14] 服务的 Java 开源实现。作为分布式协调系统，ZooKeeper 提供了配置信息管理、命名服务、分布式同步、分组等服务。

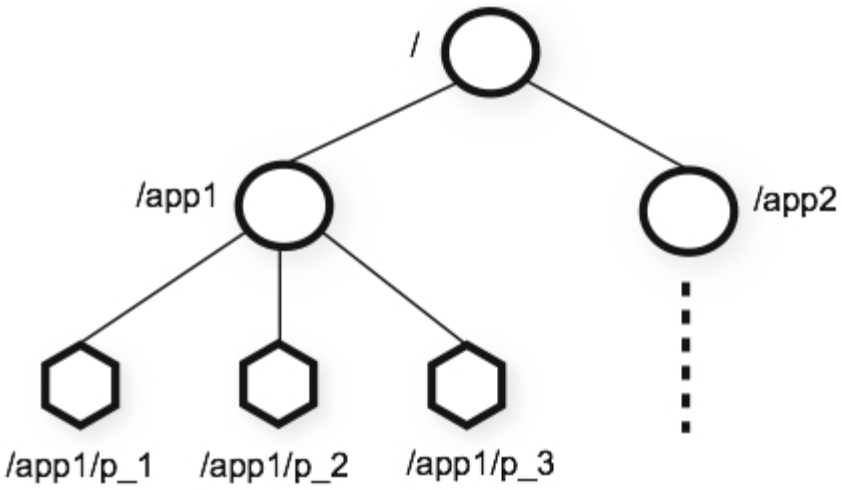

图表 3-2 zookeeper 节点结构图

如图表 3-2 所示，ZooKeeper 中采用了类似文件系统的树状结构，用户可以在某个路径上创建节点或者读写节点上附加的数据，也可以以回调的方式监听某个节点。ZooKeeper 中的节点分为暂时性和永久性，暂时性节点当客户端失去连接时，会被 ZooKeeper 删除，而永久性节点则会被永久保存。此外 ZooKeeper 为用户的更新操作提供了如下保证：

(1) 顺序一致性，即客户端的更新操作会按照发送的顺序执行。

(2) 原子性，更新操作要么成功要么失败。

(3) 单系统镜像，客户端不管连接到哪台 ZooKeeper 服务器，看到的都是统一的视图。

(4) 可靠性，一旦更新生效，它将一直持续到某个客户端覆盖了此次更新。

(5) 时效性，客户端可以在固定的时间延迟内，看到系统的最新状态。

通过 ZooKeeper 提供的操作以及以上几点保证，用户可以方便的实现各种分布式协调算法，如通过暂时性节点可监控集群中节点的状态，通过顺序创建多个暂时性节点来实现 Paxos 领导选举算法[15] ，以及实现分布式队列、分布式锁服务等等。

3.2.3异步网络通信框架

作为分布式的数据存储系统，网络通信是系统中必不可少也是影响性能的一部分。kvstore 系统采用 Mina 作为网络通信框架。Mina(http://mina.apache.org)是一款开源、基于 Java NIO 技术的网络通信框架，它具有异步、高性能、模型简单、易于使用等诸多优点：

(1) 基于异步的事件回调模型，具有高并发性。

(2) Mina 支持多种传输协议，如 TCP/IP、UDP/IP、RS232 等，封装了底层实现并提供统一的编程接口。

(3) 提供类似于 Java Servlet Filter 的过滤器，过滤器可作为扩展点，方便开发人员对消息进行预处理以及后处理。

(4) 提供底层及高级的 API，开发人员既可以直接操作二进制的消息流，也可以提供消息的编码、解码器以面向对象的方式操作消息。

(5) 高度订制的线程模型，包括单线程、单线程池和多线程池。

系统中的主服务器、数据服务以及 Java 客户端之间的网络通信完全基于 Mina 框架以及 TCP/IP 协议。具体的消息格式将在 3.7 通信模型进行详细介绍。另外系统提供了基于 C#的客户端程序，该客户端则直接采用了 Socket 直接连接到主服务器和数据服务器。

3.3 编程接口

3.3.1数据模型

(1) 键值结构

kvstore 采用键值模型作为数据模型，类似于一个大的哈希表，其中每一个键都惟一确定了一个值，并且系统不允许有重复的键以及空值出现。另外键和值在系统中都存储为二进制字节数组，而由用户来负责解释键值的含义，例如可以是字符串、序列化的对象或者其他任意的结构。

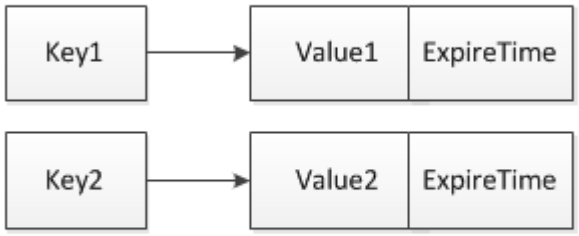

图表 3-3 键值结构图

如图表 3-3 所示，每个键分别对应了唯一值和失效时间。失效时间为 long 型的时间戳，如果服务器的当前时间超过了失效时间，那么该键值对将会被自动删除，即用户再也无法通过键取得对应值。

(2) Region 结构

Region 是从某个开始键到结束键的所有键值对的集合，也是系统负载均衡的基本单位。如图表 3-4 所示，Region 会被分配到某个唯一的服务器中，之后所有对该区域内的键值对的请求都会由该服务器所负责。

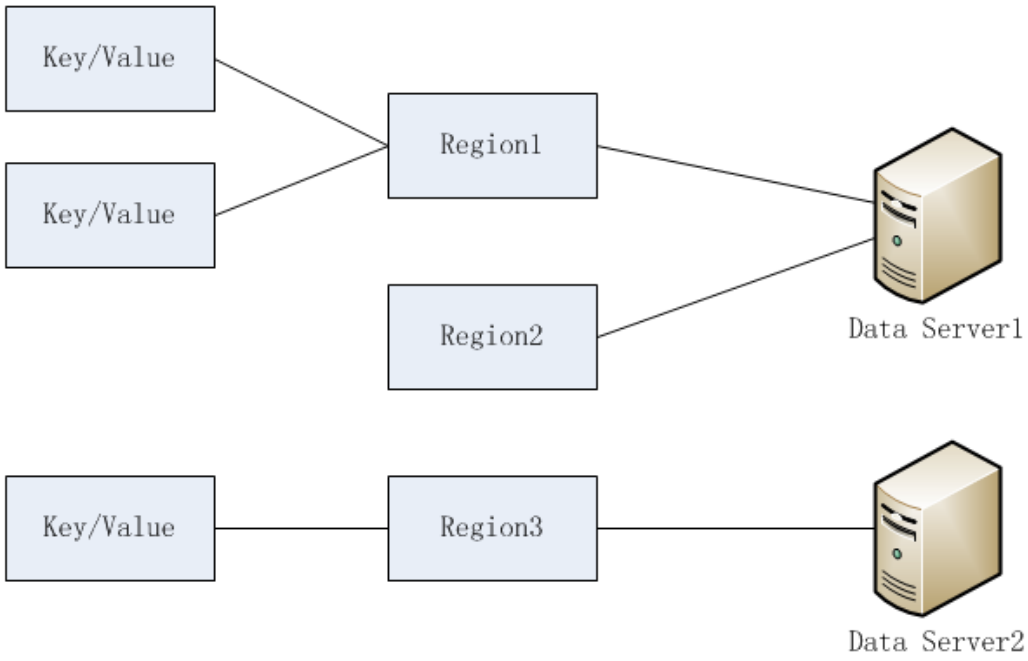

图表 3-4 Region 分配图

Region 中包含如下的属性：开始键，结束键，以及由主服务器分配的唯一的 Id。另外每个 Region 还对应了统计信息，统计的数据项包括键值对数量、大小、读次数和写次数。这些

统计信息会作为负载均衡的依据供主服务器使用。 键顺序由字节序决定，即首先按照数组的长度，长度短者小；如果长度相等，这依次按无符号字节的格式比较数组的每一位，首先出现小字节的字节数组小。

3.3.2 键值操作

kvstore 作为一个键值存储系统，支持如下几种常见的键值操作。下文中如未进行特殊说明，将按照 operation param1 [param2=value]…的格式进行说明各个操作语义，其中 operation 是操作名称，param1 是必须参数，param2 是可选参数，并且默认值为 value。

(1) set 操作

Set 操作的语义为设置某个键值对，即将一个键值对存储到系统当中。Set 操作的指令为：set key value [ttl=0]。其中 key、value 都为二进制数组，ttl 为 int 整数，指明该键值对应存活的毫秒值，默认为 0，即永久保存。

(2) get 操作

Get 操作的语义为获取某个键对应的值以及存活时间的毫秒值，并且如果键不存在，则返回空。Get 操作的指令为：get key。其中 key 为二进制数组。

(3) incr 操作

Incr 是 increment 的缩写，即增加某个键对应的整数计数器的值。Incr 操作的指令为 incr key [incremental = 1] [initValue=0] [ttl=0]。其中 key 为二进制数组，incremental 为要为计数器增加的整数值，默认为 1；initValue 为计数器的初始值，默认为 0；ttl 为计数器存活的时间毫秒值，默认为 0，即永久保存。另外计数器实际上在系统中对应了一个长度为 4 的二进制数组，如果尝试为一个值长度不为 4 的键执行 incr 操作，那么系统将返回错误信息。

(4) delete 操作

Delete 操作是在系统中删除某个键指定的键值对。Delete 操作的指令为 delete key。其中 key 为二进制数组。

(5) stat 操作

Stat 是 statistics 的简写，系统将返回包含数据服务器信息的数组，其中每个数据服务器信息对象包含了当前服务器的地址，权值，使用情况，以及其中所包含的 Region 情况。服务器的权值为用户指定的整数值，会在主服务器进行负载均衡时使用。服务器的使用情况包括服务器总的内存、当前剩余的内存以及 CPU 的使用率。由于 kvstore 基于分布式的文件系统，因此这里并未统计真实文件系统的使用情况。用户可以通过 HDFS 的管理页面进行查看。

3.4 主服务器

主服务器（Master Server）在系统扮演管理员的角色，主要负责监听集群状态、文件系统垃圾回收、Region 负载均衡等功能。集群中允许拥有多个主服务器，但是在某个时间段只有一个活动的主服务器存在。

3.4.1 架构概述

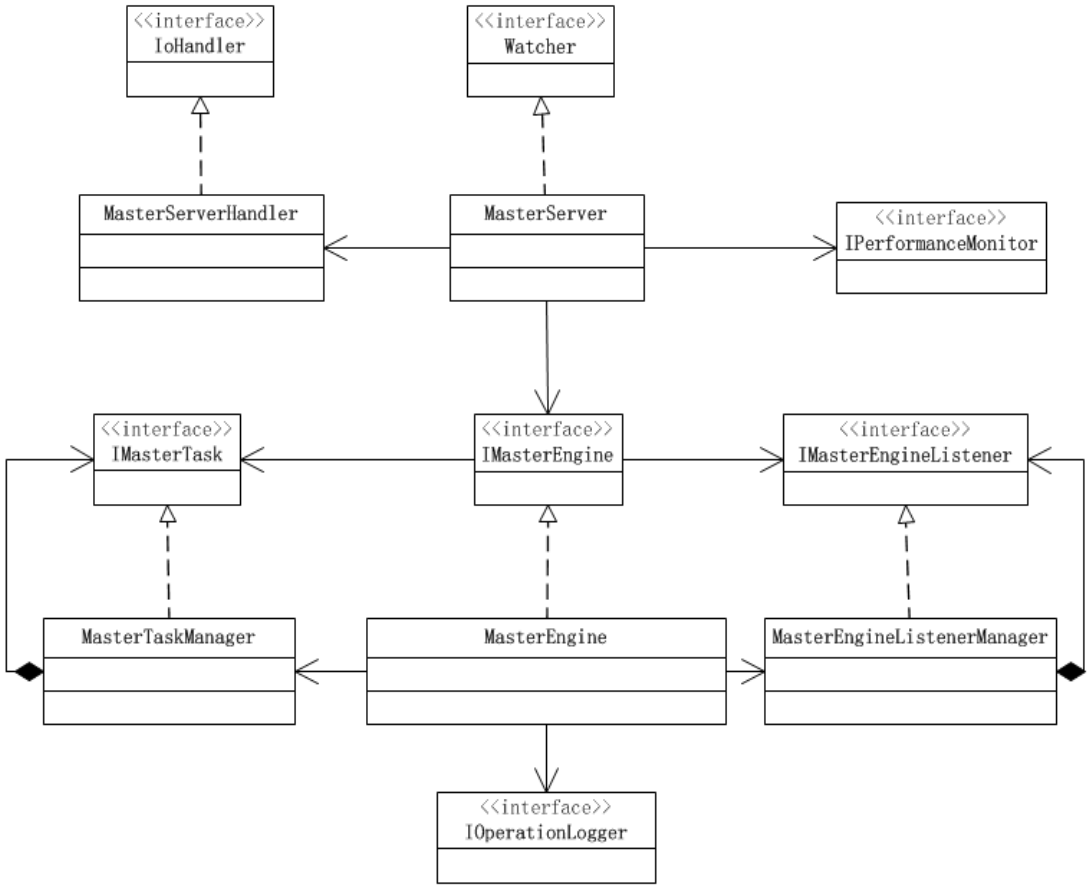

图表 3-5 主服务器类图

图表 3-5 为主服务器的主要类图，其中 IoHandler 为 Mina 框架提供的接口，当某些网络事件（例如接收消息、会话失效等）发生将被 Mina 框架调用。Watch 为 ZooKeeper 系统提供的接口，当监控的节点状态变化时将由 ZooKeeper 回调接口。主服务器通过实现 Watcher 接口来实现主服务器的领导选举算法。

(1) MasterServer

MasterServer 类是主服务器的入口点，同时负责主服务器中其他组件的初始化与资源释放工作。同时，MasterServer 类也负责响应网络连接的建立与释放，消息接收，以及监听 ZooKeeper 中节点的创建与删除动作（创建表示机器加入，删除表示机器退出）。

(2) IMasterEngine

IMasterEngine 封装了主服务器的主要逻辑，例如添加删除数据服务器服务器、Region 分配、同步数据服务器信息等。IMasterEngine 中的方法通常由 MasterServer 在某个特定的事件发生时所调用，例如收到数据服务器发送的请求或响应时。

(3) IMasterEngineListener

IMasterEngineListener 为 IMasterEngine 提供的事件监听器，IMasterEngine 在许多操作中都提供了事件点，例如数据服务器卸载，Region 拆分等，允许 IMasterEngine 的调用者动态向其中添加功能。

(4) IMasterTask

IMasterTask 定义了主服务器定时任务的接口，这些任务以单独线程的方式，并且以一个固定的时间间隔运行。由 IMasterEngine 负责任务的启动与关闭。主服务器定时任务将在 3.4.3 定时任务中详细介绍。

另外主服务器中涉及网络通信的部分，将在 3.7 通信模型中详细介绍。

3.4.2 集群状态监听

主服务器会负责对集群状态的监听。其中集群的状态包括主服务器的状态和数据服务器的状态。

(1) 主服务器状态监听

主服务器状态的监听通过 ZooKeeper 实现。当主服务器启动时，会向 ZooKeeper 中创建一个暂时性的顺序节点。其他主服务器将依次监视对方。当某个节点被 ZooKeeper 删除时，通常是由于主服务器发生故障或网络连通故障，相应的主服务器会被 ZooKeeper 触发，并开始新的领导选举的过程。同时新的领导也会向 ZooKeeper 的某节点写入当前主服务器的地址，以通知数据服务器连接。主服务器领导选举的部分将在 4.1.3 领导选举中详细介绍。

(2) 数据服务器状态监听

数据服务器状态的监听通过 Mina 框架的会话机制实现。当数据服务器启动时，它会尝试与主服务器建立连接，并通过定时的心跳消息汇报自身的情况。与此同时，主服务器会保存每一个数据服务器的状态与会话信息。当数据服务器或网络连接发生故障时，数据服务器与主服务器之间的会话会发生超时，并且主服务器的 MasterServerHandler 会收到相应的通知。

3.4.3 定时任务

在主服务器中，每个定时任务都是一个单独的线程，以定时重复执行某项操作。

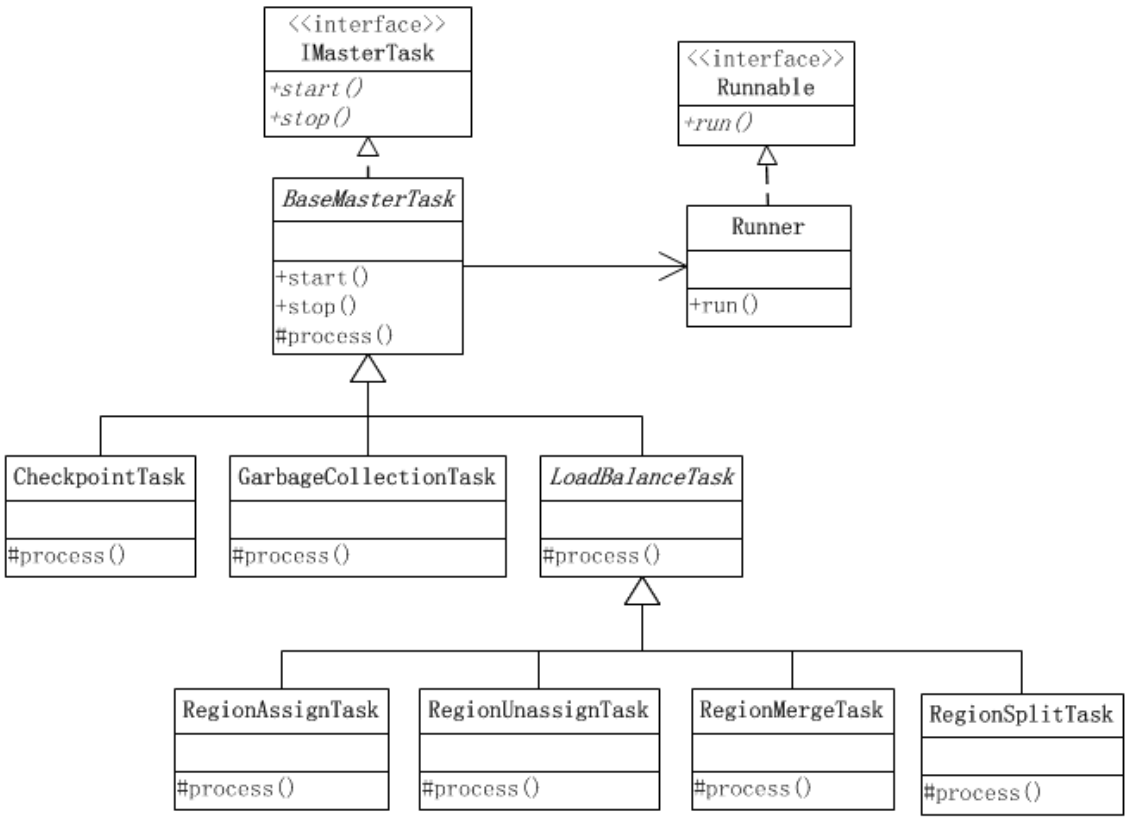

图表 3-6 主服务器定时任务类图

图表 3-6 为主服务器中定时任务的类图。定义任务采用了模板方法设计模式，每个 BaseMasterTask 中定义了抽象的 process 方法，并且该方法在线程 Runner 中被循环调用，而每个实体 Task 都实现了具体的 process 方法。主服务器中每个任务的介绍如下：

(1) 检查点任务（CheckpointTask）

检查点任务定时的将主服务器的状态保存到新的检查点文件中，并切换至新的操作日志，以控制操作日志的大小。检查点文件需要保存的状态信息主要包括每个 Region 的信息，并且主服务器在启动时会加载最新的检查点以及相应的操作日志文件。检查点任务的执行频率通常以天为单位，并且用户可指定检查点文件的保留时间。

(2) 垃圾回收任务（GarbageCollectionTask）

垃圾回收任务定时的检查文件系统中的垃圾文件以及过期的数据文件，并将其删除。由于系统在运行过程中的失败操作可能产生垃圾文件，因此通过垃圾回收任务，可以定期的检查并删除这些垃圾文件，释放存储空间。垃圾回收任务将在章节 4.5 垃圾回收中详细介绍。

(3) 负载均衡任务（LoadBalanceTask）

负载均衡任务主要负责检查每个数据服务器中的 Region 负载情况。问了简化问题，系统将负载均衡任务分为四个独立的子任务，分别为 Region 分配任务（RegionAssignTask）、Region 卸载任务（RegionUnassignTask）、Region 拆分任务（RegionSplitTask）和 Region 合并任务（RegionMergeTask）。四个子任务独立执行，但是系统保证同一个 Region 在同一个时间内只会被某一个子任务处理。例如如果 Region A 在某一时刻被 Region 分配任务选为目标，那么在

得到目标数据服务器答复之前，其他任务不会再处理 Region A。

负载均衡任务的时间间隔以秒为单位，通常 Region 分配任务的间隔应设定的比较短，以确保 Region 被卸载后可以及时被分配，而其他任务的时间间隔可比较长，以减少主服务器的资源利用。负载均衡任务将在章节 4.4 负载均衡中详细介绍。

3.5 数据服务器

数据服务器是系统中负责存储键值数据的服务器。与主服务器不同，集群中通常有多个活跃的数据服务器。另外为适应不同的应用需求，数据服务器提供了两种存储引擎，内存存储引擎和持久化存储引擎。

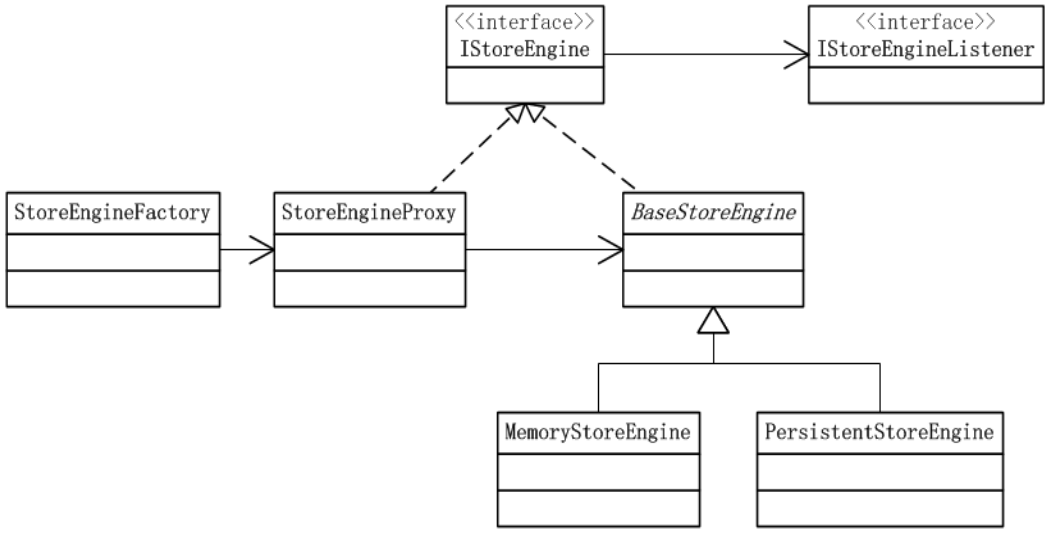

图表 3-7 数据服务器存储引擎结构图

图表 3-7 描述了数据服务器中存储引擎的基本结构。存储引擎通过代理模式进行封装，以对某些操作完成之后调用相应的监听器。存储引擎的创建采用工厂模式，根据调用者指定的存储引擎类型，工厂创建并返回相应的存储引擎代理。

3.5.1 内存存储引擎

内存存储引擎将所有的数据都保存在内存中，同时为保证数据的可恢复性，内存存储引擎在每次写操作或删除操作时都会将操作写入操作日志中。但当数据到达内存上限之后，系统会根据用户指定的置换算法删除某些键值对以释放空间。

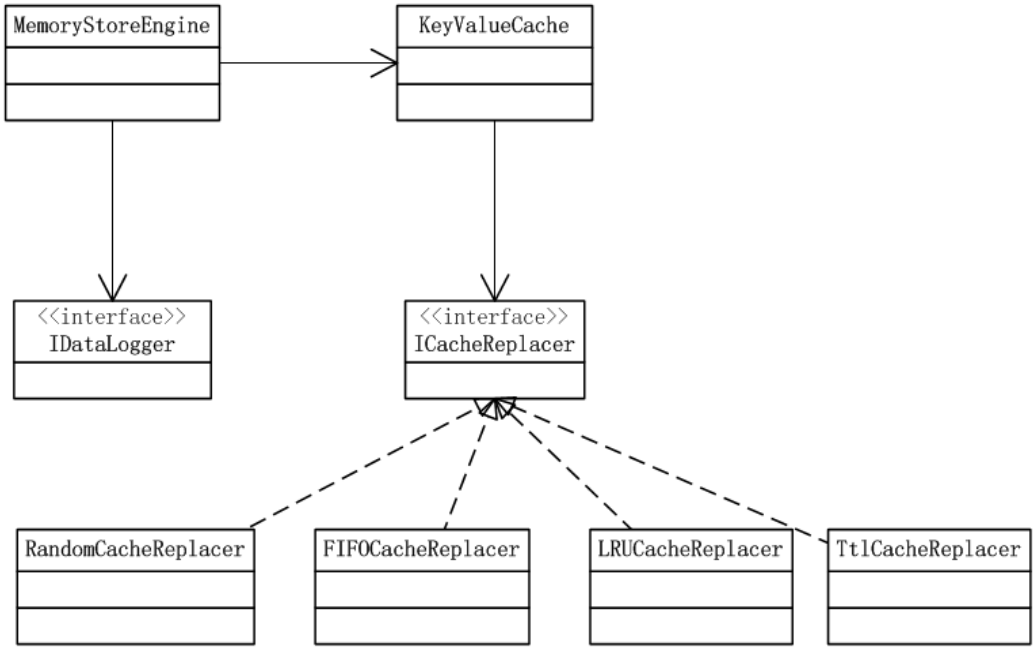

图表 3-8 内存存储引擎类图

图表 3-8 为内存存储引擎的主要类图。内存存储引擎的实现中主要用到了 KeyValueCache 组件，并且每个 Region 都对应了一个操作日志文件。KeyValueCache 负责管理内存中的键值对，并可以设置内存上限以及置换算法。目前系统中提供的置换算法包括：

(1) 随机置换算法（RandomCacheReplacer）

随机置换算法将随机选择一个键值对进行置换。其内部采用了哈希集合的实现方式。索引键添加、置换和删除的复杂度都为 O(1)。

(2) 先进先出置换算法（FIFOCacheReplacer）

先进先出置换算法按照键加入的顺序进行置换，即先进入的键将先被置换。其内部采用了队列的实现方式。索引键添加与置换的复杂度为 O(1)，而删除时则需要顺序查找，因此复杂度为 O(N)。

(3) 最近最少使用置换算法

最近最少使用置换算法优先选择最近最少使用的键进行置换，即对键按照最近访问的时间顺序排序。其内部采用 LinkedHashMap 实现。索引键的添加、删除与置换的复杂度都为 O(1)。

(4) 生存时间置换算法

由于前三种置换算法没有考虑到键值的生存时间，因此有可能将近期不会过期的键先于将要过期的键置换出内存。生存时间置换算法则将键按照存活时间排序，每次选择最先过期的键进行置换。其内部采用红黑树有序集合实现。索引键添加、删除的复杂度都为 $O(\log_2 n)$，而置换的复杂度则为 O(1)。

内存存储引擎中的响应客户端请求操作将在章节 4.3 响应请求中介绍，而 Region 的加载、卸载、拆分以及合并等操作将在章节 4.4 负载均衡中介绍。

3.5.2 持久化存储引擎

持久存储引擎将键值对数据写入到文件以达到数据的持久化存储目的。同时为了兼顾性能，键值对会首先被写入内存以及操作日志中，当内存缓冲区满时，缓冲区中的数据将被合并到数据文件中。

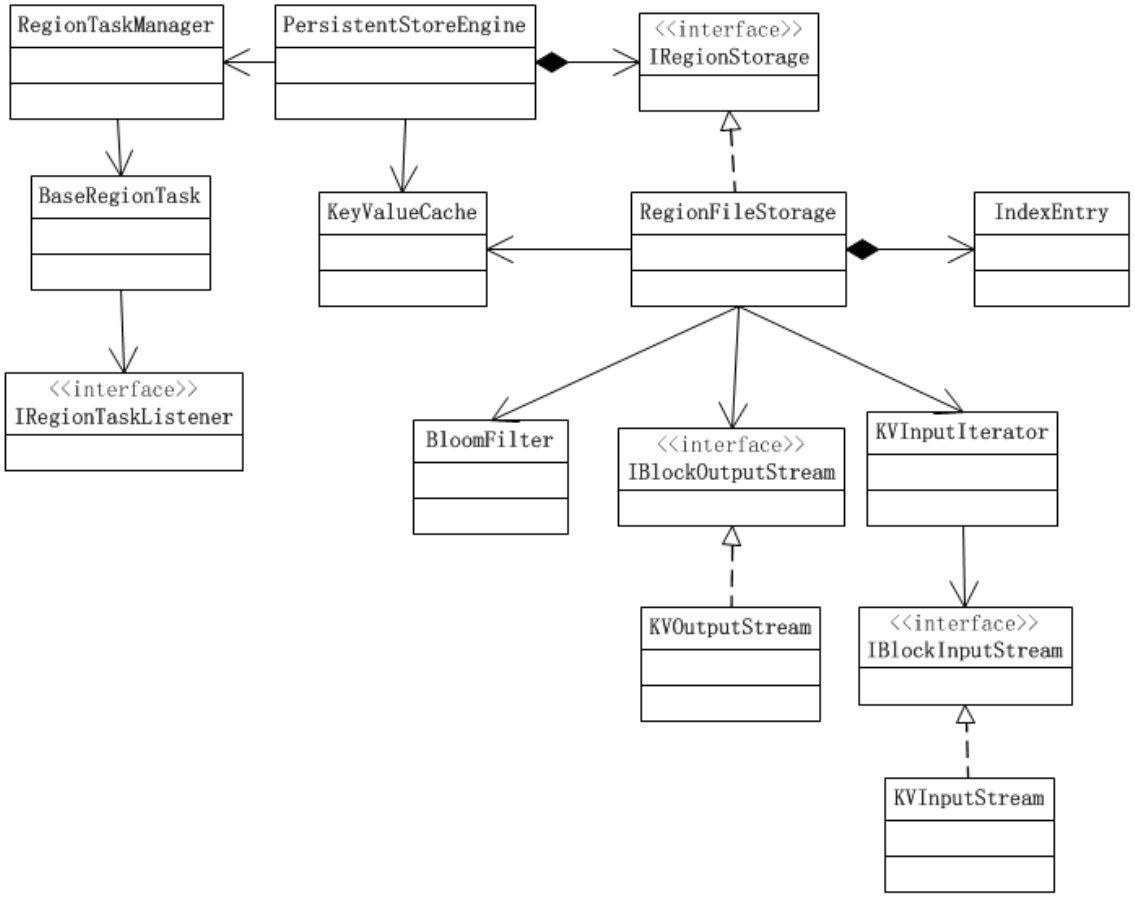

图表 3-9 持久化存储引擎类图

图表 3-9 介绍了持久化存储引擎的主要类图。其中实现了 IRegionStorage 接口的 RegionFileStorage 负责某个 Region 的存储与读取。同时为减少文件系统的 IO 操作，写操作也会被直接写入到内存缓存当中。

(1) PersistentStoreEngine

PersistentStoreEngine 是持久化存储引擎实现类。在持久化存储引擎中，每个 Region 都对应了一个 IRegionStorage 来负责的 Region 中数据的持久化存储。而持久化存储引擎则负责调用 IRegionStorage 中的方法，以响应客户端及主服务器的请求。

(2) IRegionStorage

IRegionStorage 定义了 Region 持久化存储的接口。同时系统提供了基于分布式文件系统 HDFS 的 RegionFileStorage 实现。IRegionStorage 提供的方法包括键值写入缓冲、读取键值数据、获得数据文件路径以及提交内存缓冲区等，以供 PersistentStoreEngine 调用。

(3) BloomFilter

BloomFilter 是 1970 年由布隆提出的一种高效的用于检查元素是否在集合中的算法[16] 。它实际上由一个长二进制串和一系列的哈希算法组成，并且具有很高的空间效率和时间效率，但是一定几率把不存在的元素判定为存在。持久化存储引擎通过使用 BloomFilter 以减少数据文件的 IO 操作，如果 BloomFilter 判定某个键肯定不在集合中时，便无需执行 IO 操作。

(4) IO 组件

系统提供了适合键值文件结构的文件输入流和输出流以满足读写文件的需求，同时采用迭代器的模式对文件读取进行封装，使得读取文件可以遍历集合一样操作。关于键值数据文件的具体格式将在章节 3.5.3 文件中介绍。

(5) RegionTask

由于持久化存储引擎 Region 相关的操作（例如 Region 拆分、合并、加载、卸载等）比较复杂，并且持续时间较长，因此为了兼顾性能并且提高并发性，系统采用异步任务的方式执行 Region 操作。Region 任务将在章节 3.5.5 任务线程中详细介绍。

3.5.3文件格式

在持久化存储引擎中，Region 数据文件采用二进制流的方式进行存储，同时文件分成大小固定的块（通常为 64K）以方便对文件进行索引。

Entry Length int	Key Length Int	Key byte[]	Value byte[]	Expire time long

图表 3-10 键值项结构图

图表 3-10 描述了每个键值项在数据文件中存储的格式。其中值的长度可以根据项的长度与键的长度推算出来。同时，由于文件块采取固定长度，因此有可能出现某个键值项在结束之前遇到了块的末尾，甚至跨越多个文件块的情况。在这种情况下，如果块中剩余的字节数不足以容纳单独的 int 或 long，那么文件中将补 0，同时将数据写入下一个块中。另外数据文件末尾块没有填满，那么末尾块空白的部分也将全部补 0。

系统定义了 IBlockInputStream 和 IBlockOutputStream 接口以进行数据文件的读写操作，同时提供了 KVInputStream 和 KVOutputStream 默认实现。

在 KVInputStream 中，读取操作基于块来进行，每次 KVInputStream 将文件中的一个块读入内存中，然后基于内存流进行读取。同时，KVInputStream 允许在一个内存块之内进行随机读取。

同样在 KVOutputStream 中，会保存当前块的编号以及偏移量，并且在写入 int 以及 long 等数据时，会检查如果当前如果已经到达块末尾，那么将先进行补 0。同时写入数据后，会更新当前块号以及偏移量。

KVInputIterator 通过迭代器模式对文件读取进行封装。迭代器首先会尝试读取 4 个字节，

即下一个项的长度。如果长度大于 0，说明文件中仍有数据项存在，此时迭代器会将流的当前偏移前移四位，并允许调用者读取下一个数据项；否则说明文件中已无数据项存在，迭代器将关闭当前数据文件。

3.5.4索引结构

Region 数据文件中的键值项按照键的升序排列。因此为了提高键值项文件的查找效率，持久化存储引擎在加载某个 Region 时，会首先遍历 Region 的数据文件并建立索引。每个索引项中包含开始键、结束键、开始块编号、结束块编号，以及开始块偏移。

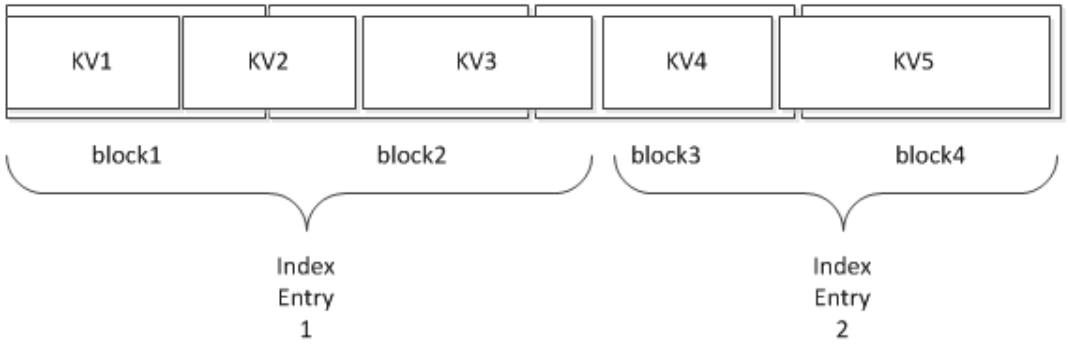

图表 3-11 数据文件索引结构图

系统允许用户指定每个索引项中涵盖的块数目，但是由于可能有某个键值项跨越多个块的情况存在，系统会保证每个索引项的块数目为不小于用户指定值的并且可行的最小值。例如图表 3-11 描述了四个数据块、五个键值项以及每个索引号中涵盖的块数目为 2 的情况。其中索引项 1 为：开始键 key1，结束键 key3，开始块 block1，结束块 block3，开始块偏移 0；索引项 2 为：开始键 key4，结束键 key5，开始块 block3，结束块 block4，开始块偏移为 KV4 在 block3 中的开始位置。

当系统从文件中读取某个键值项时，系统会首先查找到对应的索引项，然后将索引项中涵盖的数据块全部加载入内存。因此用户通过调整数据文件块大小以及索引项中的块数目，可以对系统的查找性能进行优化。一个典型的配置为块大小 64KB，而索引项中的块数目为 5，以平衡索引项的数目以及每次从文件中载入的数据大小。

3.5.5任务线程

在持久化存储引擎中，Region 操作例如合并、拆分以及提交等较为复杂，并且涉及到文件 IO 处理，因此为了避免此类操作阻塞持久化存储引擎的工作线程，系统采用多线程任务的方式实现此类操作。另外，由于这类操作执行中需要对 Region 的内存加锁，并会阻止其他线程读写该块内存，因此为减少对其他线程的阻塞，系统规定某一时间内只允许有一个任务线程运行。

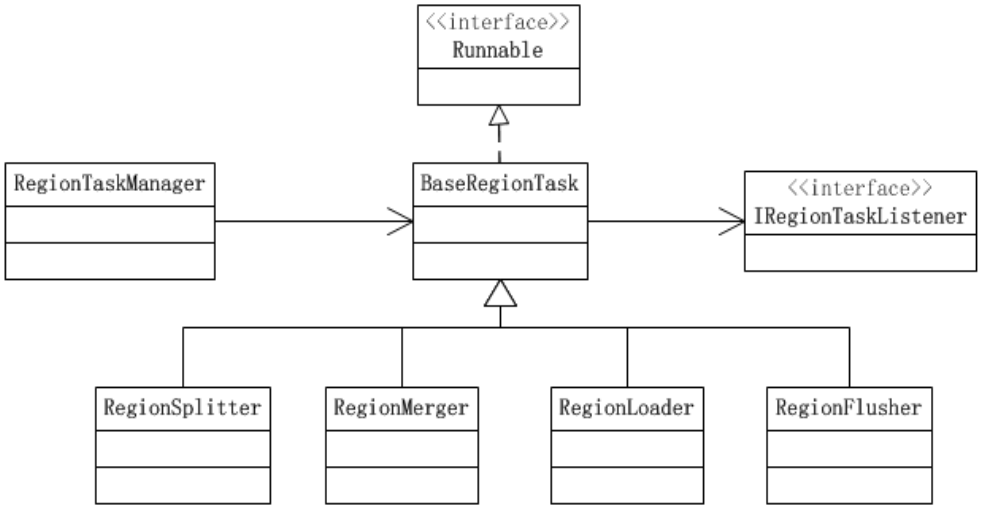

图表 3-12 持久化存储引擎任务线程类图

图表 3-12 描述了持久化存储引擎中的任务线程。其中每个任务都实现了 Java 的 Runnable 接口，可作为单独的线程启动。

(1) RegionSplitter

RegionSplitter 负责将某个容量过大的 Region 拆分成两个。在拆分过程中，RegionSplitter 会尽量将 Region 按照当前容量平均分成两个，并且以监听器回调的方式通过存储引擎拆分的结果。

(2) RegionMerger

RegionMerger 主要负责将两个容量都过小的 Region 合并为一个新的 Region，两个 Region 在键范围上必须连续。

(3) RegionLoader

RegionLoader 主要负责加载某个给定的 Region。RegionLoader 需要遍历数据文件以建立索引，同时将操作日志中的数据载入缓存。另外由于 RegionLoader 不会阻塞数据服务器请求线程，因此通常以同步的方式调用。

(4) RegionFlusher

RegionFlusher 主要负责当某个 Region 写缓冲容量满之后，将写缓冲的数据写入数据文件。RegionFlusher 会保证结果文件中的键值数据以键升序排列，同样为了保证可靠性，旧的数据文件不会被删除，而是等主服务器的垃圾回收任务进行回收。

(5) RegionTaskManager

RegionTaskManager 负责启动任务线程，并且通过互斥信号量以确保同一时间内只有一个任务线程执行，线程执行完之后会将信号量修改为闲置状态。当尝试启动任务线程时，RegionTaskManager 会检查互斥信号量，并返回是否启动成功，如果失败，则只需重试调用即可。

操作线程中具体的算法将在章节 4.4 负载均衡中详细介绍。

3.6 客户端

客户端程序库（下文简称客户端）是系统提供给应用程序以使用系统数据存储服务的程序库。目前系统已提供了基于 Java 和 C#的客户端，并且只要按照章节 3.7.2 消息格式定义的消息格式，便可基于 Socket 连接实现任意语言的客户端。

客户端应封装动态路由、网络通信等功能，并实现系统定义的编程接口。其中动态路由将在章节 4.4.1 自动路由中详细介绍。

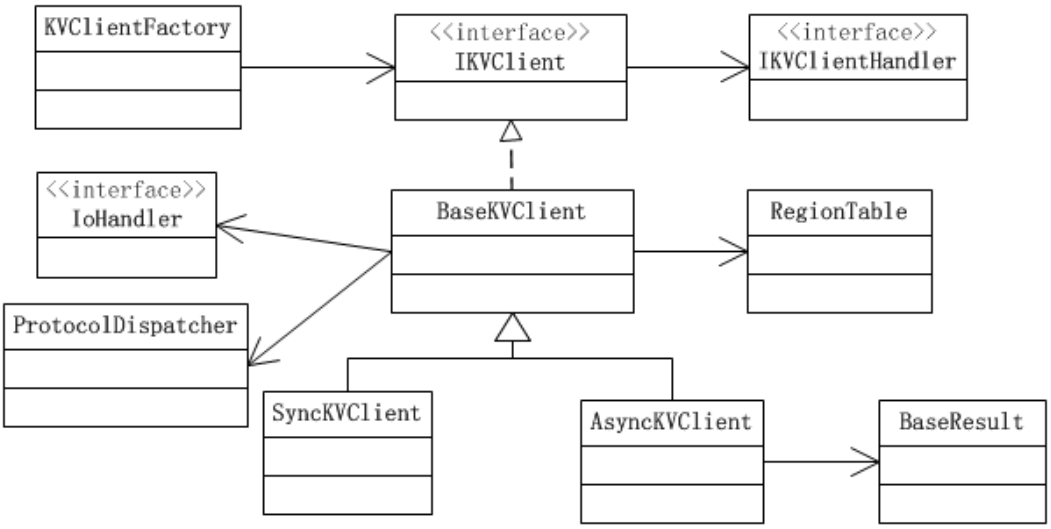

图表 3-13 客户端类图

图表 3-13 描述了系统 Java 客户端的主要类图。其中 IoHandler、ProtocolDispatcher 等组件将在章节 3.7 通信模型中统一介绍。

(1) IKVClient

IKVClient 定义了系统客户端的主要接口，例如 get、set、更新 Region 表、关闭客户端等操作。

(1) SyncKVClient

SyncKVClient 为 IKVClient 基于同步模型的实现，即所有的调用操作都为同步执行。SyncKVClient 的具体实现将在章节 3.6.1 同步模型中详细介绍。

(2) AsyncKVClient

AsyncKVClient 为 IKVClient 基于异步模型的实现，开发者需要实现 IKVClientHandler 并注册到客户端中，并且会由 AsyncKVClient 取得结果时进行回调。AsyncKVClient 的具体实现将在章节 3.6.2 异步模型中详细介绍。

(3) Region 表（RegionTable）

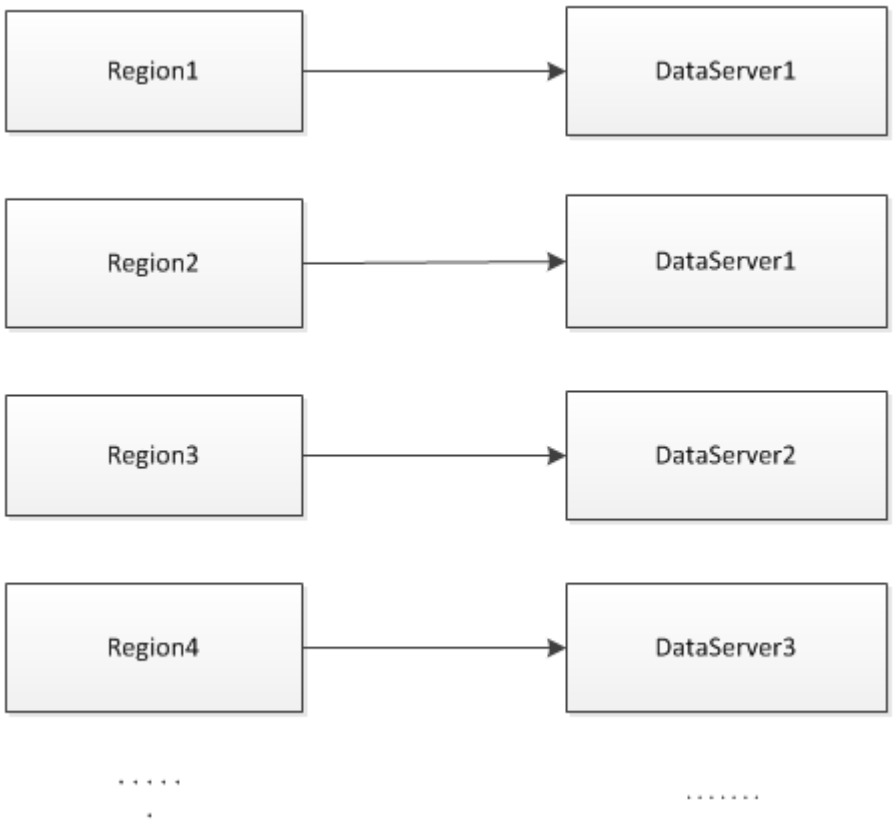

图表 3-14 Region 表结构图

Region 中定义了键到数据服务器的映射关系，并且由主服务器负责管理。图表 3-14 描述了 Region 表的基本结构。在 Region 表中，包含有序的 Region 数组和 Region 到数据服务器地址的哈希表。当需要查找某个键对应的数据服务器时，首先通过二分查找法在 Region 数组中查到相应的 Region，然后再从哈希表中拿到对应的地址即可。整个查找过程的时间复杂度为 $O(\log_2 n)$，其中 n 为 Region 数量。

3.6.1同步模型

在 SyncKVClient 中，接口中的方法都以同步的方式实现。但是由于 Mina 框架本身是异步的网络通信框架，因此客户端在 Mina 传输消息之后，会阻塞当前线程，并且当 Mina 的事件处理线程收到消息之后，再唤醒当前线程。

同步模型使用简单，易于理解，符合开发人员常规的编程习惯。但缺点是会阻塞当前线程，并且由于网络传输的等待时间可能较长，不利于程序的快速响应以及高并发性。

3.6.2异步模型

在 AsyncKVClient 中，开发人员需要实现客户端定义的 IKVClientHandler 接口，并且在某些事件发生时由客户端进行回调。例如对于 get 操作，开发人员需要首先调用 AsyncKVClient 中的 get 方法，之后当数据服务器返回结果时，客户端会调用 IKVClientHandler 中的 onGet 方

法，并传入 GetResult 参数。GetResult 中包含了键、值、生存时间信息以及异常信息，当有异常发生时，GetResult 会在开发人员尝试获得结果值时抛出异常，以此强制开发人员处理错误情况。另外 AsyncKVClient 中的方法都将返回空值或 0，通常是无意义的。

异步模型的调用不会阻塞当前线程，而是通过在客户端的线程池中执行操作，并以回调的方式通知应用程序结果，因此可以在应用程序线程中同时进行多次调用，有利于提高应用程序的并发性。然而异步模型较为复杂，需要开发人员将传统的串行执行的代码，拆分成监听器回调的方式，可能会增加程序的复杂度。因此异步模型较适合数据访问密集型而非计算密集型的应用。

3.7 通信模型

3.7.1 模型概述

系统的网络通信采用 Mina 的异步通信模型实现，即基于异步消息机制完成网络 IO 操作。

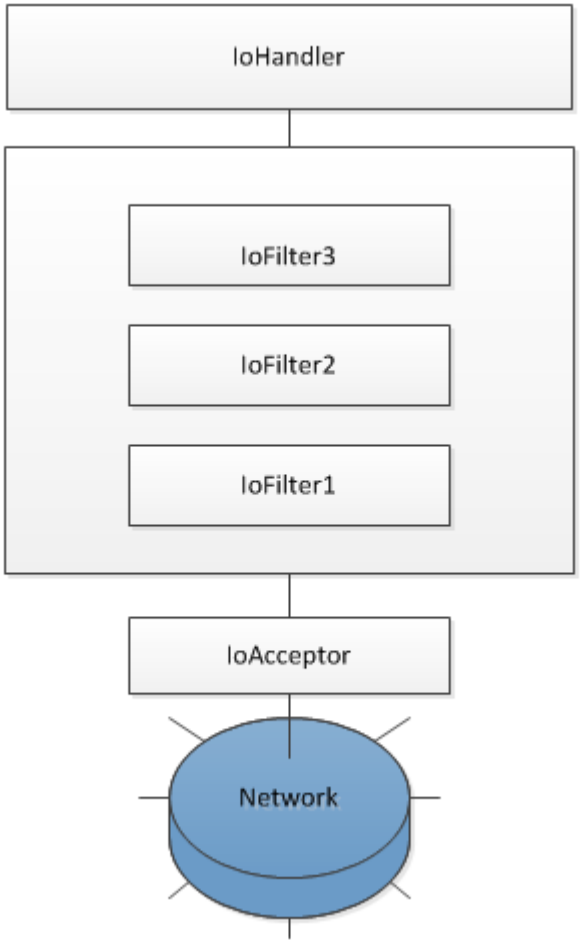

图表 3-15 Mina 架构图

图表 3-15 描述了 Mina 构建的 TCP 服务器的网络通信模型。最底层的 IoAcceptor 负责创建 Socket 连接点，并绑定到机器的 IP 和端口上；中间层为过滤器组成的调用链，过滤器可对

消息进行编码、解码，或者记录日志等操作；最顶层为用户定义的 IoHandler，当网络事件发生时被 Mina 回调。

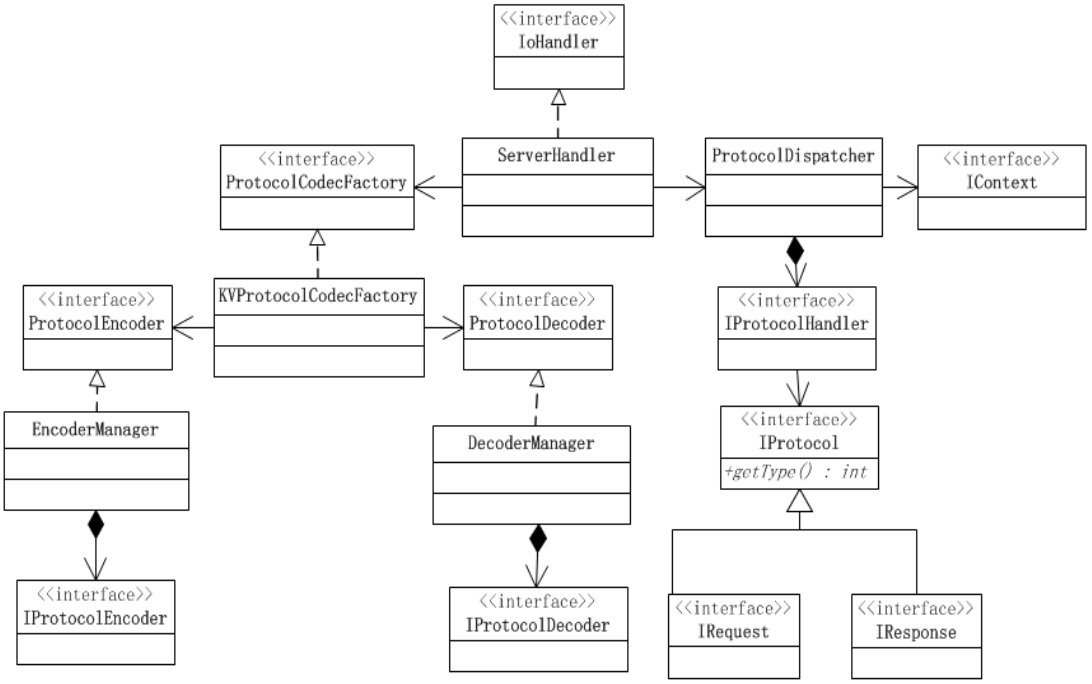

图表 3-16 通信模型类图

系统在 Mina 网络通信模型的基础上加以封装，将每个请求与响应都封装为对象，并根据消息类型，分派到对应的消息处理器。同时每个消息都有对应的编码器和解码器，以允许消息对象进行网络传输。图表 3-16 描述了系统通信框架，其中省去了 IProtocol、IProtocolEncoder 和 IProtocolDecoder 的具体实现类。

(1) ServerHandler

ServerHandler 是 IoHandler 的实现类。当网络事件发生时（收到消息），ServerHandler 中相应的方法会被 Mina 调用。ServerHandler 将根据消息的类型通过 ProtocolDispatcher，把消息交由对应的 IProtocolHandler 进行处理。

(2) IProtocol

IProtocol 接口定义了服务器间以及客户端与服务器间交互的消息类。其中每个消息都必须有唯一的类型值，供 ProtocolDispatcher 进行消息分发以及消息的编码器、解码器使用。

(3) IProtocolHandler

IProtocolHandler 是定义了系统中消息处理接口，其中每一种消息都对应了一个 IProtocolHandler 的实现，并注册到 ProtocolDispatcher 中，以供 ServerHandler 进行调用。

(4) 编码器/解码器

编码器/解码器的作用是负责消息对象与二进制流之间的转换。服务器之间的消息对象传输时，为了简单，直接使用对象序列化机制进行传输；而对于客户端与服务器之间的消息，

为了支持多语言版本的客户端，则需要提供相应的编码器/解码器实现消息对象与二进制流之间的转换。具体的消息格式将在章节 3.7.2 消息格式中详细介绍。

通过上述的通信模型，为系统添加新的消息只需要定义 IProtocol 的实现类，实现对应的 IProtocolHandler，同时根据消息类型注册到 ProtocolDispatcher 中。另外如果消息涉及到客户端交互，则另外需要按照系统的消息对象格式定义消息的编码器和解码器。

3.7.2消息格式

消息格式定义了实现了 IProtocol 的消息对象到二进制流的相互转换规则。系统的网络消息采用定长头+变长体的格式（图表 3-17），即每个消息开头都为四字节的整数以标明变长消息体的长度。

图表 3-17 定长头消息格式图

关于消息格式有如下几点约定：

(1) 数据的网络传输都采用大字节序（Big-Endian）的格式。

(2) 对于二进制数组的传输，采用四字节整数的长度头加内容的格式。

(3) 字符串当作二进制数组进行传输，并且字符集都为 UTF-8。

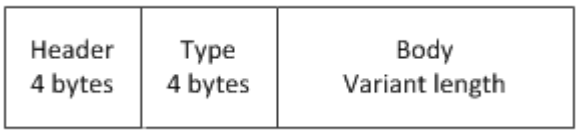

图表 3-18 消息格式图

图表 3-18 简要描述了系统中的消息格式。每个消息开头都是四字节的整数以指明消息的长度，和四字节整数以指明消息类型。对于服务器之间通信的消息对象，消息体中直接包含序列化后的消息对象，同样接收者也可直接通过反序列化的方式读出消息对象；而对于客户端与服务器之间通信的消息对象，则按照消息对象中字段的顺序，依次将字段值写入二进制流，读取时同样依次按照字段顺序读出即可。

例如，GetRequest 为客户端根据键查找值的请求，GetRequest 中的字段包括（表格 3-1）：

类型	名称	含义
boolean	retry	客户端是否要进行重试
byte[]	key	要查找的键

表格 3-1 GetRequest 字段表

对应的消息格式为（表格 3-2）

类型	含义
int	消息长度

int	消息类型
byte	0 表示 false，1 表示 true
int	键长度
byte[]	键数据

表格 3-2 GetRequest 消息表

由于系统中定义的消息对象较多，由于篇幅限制，本文中不再一一列举。具体可参考系统提供的 JavaDoc 以及源码。

4 功能实现

4.1 集群启动与关闭

系统中包含有主服务器、备份主服务器和数据服务器三种类型的服务器，因此为保证系统的正常工作和运行，三种服务器应有正确的启动和关闭顺序。

4.1.1 启动顺序

集群启动时，推荐应首先启动所有的主服务器，等主服务器全部就绪之后，再启动数据服务器。

(1) 启动主服务器

主服务器可通过运行系统提供的脚本“master_server.bat”启动，同时应保证系统所需的配置文件在类路径中。主服务器可以同时启动多个实例。

(2) 领导选举

所有的主服务器启动后将参与到领导选举算法中，其中被选举出来的主服务器将在 ZooKeeper 中创建“/kvstore/master/addr”节点，并将自己的 ip 地址和端口存入该节点中。另外，被选举出的主服务器将加载 HDFS 中“/kvstore/master/checkpoint/”目录下最新的检查点以及“/kvstore/master/log/”中相应的日志文件的 Region 信息，并将所有的 Region 放入待分配 Region 集合中。而备份主服务器将在领导选举后暂停，以等待下一次领导选举算法的执行。主服务器的领导选举算法将在章节 4.1.3 领导选举中详细介绍。

(3) 启动数据服务器

数据服务器可通过运行系统提供的脚本“data_server.bat”启动。数据服务器启动后，会在 ZooKeeper 中查看“/kvstore/master/addr”节点，如果节点不存在，则等待一段时间后重试；否则取得节点中保存的 ip 地址和端口，并尝试进行连接相应的主服务器。

(4) 建立连接

主服务器收到数据服务器的连接建立请求时，会检查当前已连接的数据服务器中是否包含新连接的数据服务器，以避免重复连接的情况。之后主服务器会将新的数据服务器添加到数据服务器表中。如果数据服务器先于主服务器启动，并且自身已拥有了某些 Region，则数据服务器会通过定期心跳的方式将自身包含的 Region 汇报给主服务器，而主服务器则会进行同步。

当所有数据服务器启动完毕后，主服务器的任务线程将开始定期执行（用户可设置任务

线程启动前的等待时间）。之后通过 Region 分配任务，系统中所有之前已存在但未被分配的 Region 将分配给对应的数据服务器，整个系统便可正常的响应客户端请求。

4.1.2 系统关闭

对于主服务器或数据服务器的关闭，只需通过 ctrl+c 命令关闭“master_server.bat”和“data_server.bat”即可。

(1) 关闭备份主服务器

首先应关闭所有的备份主服务器，以防止当主服务器先关闭时，后续的备份服务器又会被选举为新的主服务器。

(2) 关闭主服务器

备份主服务器关闭后，便可主服务器。主服务器关闭时会将相应的日志文件关闭，并断开与 ZooKeeper、HDFS 以及所有的数据服务器之间的连接。

(3) 关闭数据服务器

当主服务器与数据服务器断开时，数据服务器会自动尝试进行重连，但如果用户设置了最大尝试次数，那么数据服务器将在超过次数之后自动关闭。如果用户设置最大尝试次数为无限，那么用户需要手动的关闭数据服务器。

由于主服务器与数据服务器在关闭时会执行相应的资源清理、关闭文件、写入缓存等操作，因此尽量不用使用杀死进程的方式关闭，这样会使某些系统关闭应执行的代码无法执行，从而可能导致数据丢失的情况发生。

4.1.3 领导选举

主服务器的领导选举算法的实现基于 Paxos 算法[15] ，具体步骤如下：

(1) 创建顺序节点

每个主服务器启动之后，都会在 ZooKeeper 中的“/kvstore/master/”目录下创建暂时顺序性节点。节点的名称由 ZooKeeper 以递增序列的形式分配。

(2) 选举

主服务器在创建完节点之后，会检查“/kvstore/master”中的所有节点。如果当前服务器创建的节点值为节点中的最小值，那么该主服务器就成为领导，否则它将成为备份主服务器，并且监听它前面一个节点的状态变化。

(3) 监听

对于备份主服务器，如果它所监听的节点被删除（即对应的服务器发生故障，与 ZooKeeper 失去连接），那么它将重新执行第二步的选举算法。

领导选举算法假定每个主服务器都是平等的，并且严格按照主服务器在 ZooKeeper 中创建节点的时间顺序进行选举，以此保证了公平性。同时，每次当某台主服务器离开集群中，只会唤醒一台主服务器重新执行选举算法，由此避免了羊群效应。

例如，三台主服务器启动后，分别在 ZooKeeper 中创建了名为 1、2、3 的三个节点。因此基于该算法，1 将成为主服务器，2 和 3 成为备份主服务器，并且 2 将监听 1，3 将监听 2（图表 4-1）。

图表 4-1 领导选举示例图 1

在某一时刻，2 因为故障失去与 ZooKeeper 的连接，此时节点 2 会被 ZooKeeper 删除，并且 3 将被唤醒以重新执行选举算法。算法的结果为 3 将监听 1（图表 4-2）。

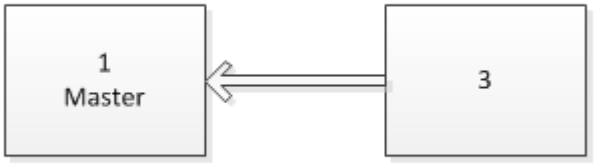

图表 4-2 领导选举示例图 2

最后，1 也失去了与 ZooKeeper 的连接，此时节点 1 会被 ZooKeeper 删除，并且唤醒 3。3 通过执行选举算法发现自己成为主服务器（图表 4-3）。

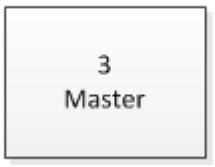

图表 4-3 领导选举示例图 3

4.2 故障恢复

在系统运行过程中，各个服务器组件难免发生故障。系统通过基础设施、功能实现、以及对故障情况的具体分析等方面，以提供较好的容错机制。

4.2.1 可靠性保证

(1) HDFS

HDFS 本身就是一个具有高度容错性的文件系统，适合在普通的机器上提供高可靠性的文件系统服务。HDFS 把硬件故障作为分布式系统的一部分，并提供数据的副本机制以避免数据丢失，以及基于文件块的校验码以快速检测故障。系统假定存储在 HDFS 中的文件是可靠的，容错的，而无需系统额外通过数据副本机制来保证数据的可靠性。

(2) 操作日志

对于任何会导致系统状态变化的操作，系统都会将其写入到操作日志中，以允许当故障发生时，系统可以从操作日志中对状态进行重建。同时，系统保证了此类操作的幂等性，即操作被执行一次或多次的效果等价。主服务器中的操作日志主要记录 Region 的分割与合并操作，数据服务器中主要记录键值的 set 和 delete 操作。

(3) 功能实现

系统在功能实现的编码层面上，同样对可靠性进行了考虑。例如主服务器中会同时保存一段时间之内的检查点文件，以允许最新检查点文件损坏时，系统可以从老的检查点文件恢复状态。另外主服务器的负载均衡任务将连续的事务分解为相互独立的子任务，以保证某一个任务的失败不会影响到其他任务的执行。同时，为保证系统的正确性，系统做了充分的单元测试、系统测试等，并通过模拟在真实环境下应用程序的请求，对系统进测试。

4.2.2 主服务器故障

对于传统的主从式服务器架构，容易出现单点失效问题，当主服务器失效时，会导致整个系统的瘫痪。系统通过引入备份主服务器机制，可以有效的避免单点失效问题。

当主服务器失效时，某个备份主服务器会被唤醒，并将成为新的主服务器。之后，新的主服务器会加载检查点文件和对应的操作日志，以获得系统中所有存在的 Region，重建主服务器之前的状态。同时所有的数据服务器在主服务器失效时也会收到通知，并尝试连接到新的主服务器中。连接建立后，数据服务器通过定时心跳汇报自己拥有的 Region 信息。通过上述机制，当主服务器失效时，新的主服务器会马上接替原主服务器的工作，整个系统状态不会丢失。

即使当主服务器全部失效，数据服务器在一定时间内仍处于部分可用的状态。对于那些已经从主服务器中拿到 Region 表的客户端，仍然可以通过已有的 Region 表向相应的数据服务器发起请求，并且数据服务器也可进行响应。

4.2.3 Data 服务器故障

当数据服务器发生故障时，主服务器将收到相应的通知，并且将其从数据服务器表移除。另外，对于该数据服务器所负责的 Region，将被放入未分配 Region 集合中。当主服务器的 Region 分配任务执行时，会将未分配的 Region 按照 Region 分配算法，分配给其他的数据服务器。数据服务器收到加载 Region 的请求时，会读取文件系统中的数据文件以及相应的日志文件，以加载 Region 中的数据。经过上述的一系列工作之后，发生故障的数据服务器中的数据会被分配到其他数据服务器中，因而系统可以继续提供服务。

4.3 响应请求

对于客户端的键值请求，如 get、set 等，数据服务器都会先检查负责的 Region 中是否包含请求的 key。如果不包含，则直接返回客户端“Invalid_Key”。因此下面的操作流程都假定数据服务器所负责的 Region 中包含请求的 key。另外，当键值操作执行完后，引擎代理类调用所有引擎监听器中的相应的回调方法，以通知监听器。

4.3.1 set 操作

对于内存存储引擎，需要执行如下操作：将键值对放入内存中，并在内存满时置换出某些键值对，同时写入操作日志。而对于持久存储引擎，除了上述之外，同时需要将键值对放入写缓存中。当写缓存满时，持久存储引擎将尝试启动 RegionFlusher 任务，将写缓存中的数

据写入数据文件，具体步骤如下：

(1) 检查当前是否有任务线程在执行，如果是，则退出。

(2) 在 Region 目录下创建名为“$timestamp”的临时数据文件，其中“$timestamp”为当前时间戳。

(3) 创建新的写缓存，并读入之前的数据文件，与老的写缓存中的数据一起按键的顺序写入到新的数据文件中，类似于归并排序中的归并操作。

(4) 完全写入后，持久存储引擎尝试遍历新的数据文件，并建立索引，以保证数据文件的正确性。当索引创建无误后，清空老的写缓存中的数据，否则将老写缓存与新写缓存中的数据合并。

(5) 将之前创建的临时数据文件重命名为“$regionid-$timestamp.data”，并且创建新的名为“$regionid-$timestamp.log”的日志文件，其中“$regionid”为 Region 的 Id，“timestamp”为当前时间戳，并且数据文件与日志文件的时间戳相同。

持久存储引擎采用两步提交的方式以保证数据写入的正确性，当写入文件失败时，操作会异常退出，同时临时数据文件的名字不会变为合法的数据文件名。在之后主服务器的垃圾回收操作中，由于失败操作产生的临时文件会被删除。

装

4.3.2 get 操作

内存存储引擎的 get 操作需检查内存中是否存在该键值对，并且如果存在还需要检查键值对是否存活可，只有当键值对存在并且仍旧存活时，内存存储引擎才会返回该键值对。

对于持久化存储引擎，则比较复杂，需要检查写缓存、内存以及文件等，具体步骤如下：

(1) 从写缓存中通过键查找键值对，如果键值对存在，直接转到(5)。

订

(2) 从内存中通过键查找键值对，如果键值对存在，直接转到(5)。

(3) 通过 BloomFilter 初步判断是否存在与数据文件中，如果不存在，则存储引擎直接返回空。

(4) 找到键对应的索引项，并将索引项对应的块全部载入内存，同时查找是否存在键对应的键值对。如果不存在，存储引擎直接返回空。

线

(5) 现在已经取得了键值对，需要检查键值对是否仍然存活和删除标志位（isDeleted，只针对写缓存中的键值对）。如果键值对存活并且未被删除，则返回键值对，否则返回空。

4.3.3 incr 操作

Incr 操作可以拆分为 get 操作和 set 操作，具体的 incr 操作过程如下：

(1) 通过 get 操作，得到对应的键值对。

(2) 如果键值对为空，则新建键值对，并且将值设为用户指定的计数器初始值；否则如果值的长度为 4，则将值加上用户指定的增量，否则抛出异常。

(3) 将新的键值对通过 set 操作放入存储引擎中。

对于内存存储引擎和持久化存储引擎，只是 get 与 set 的具体实现不同，而 incr 操作的流程二者则基本相同。

4.3.4 delete 操作

Delete 操作比较简单，对于内存存储引擎，只需要将对应的键值对从内存中删除，并且记录操作日志；而对于持久化存储引擎，除了上述操作外，还需要在写缓存中放入一个键为请求键、并且标志位 isDeleted 为真的键值项，以在下一次缓存提交操作中，删除原有数据文件

中的键值对。

4.3.5stat 操作

，简化系统的编程模型，stat 操作采用定时更新的方式进行对 Region 的统计操作。因此，Region 的统计信息会有一定时间的延迟和误差，但对于大规模的数据，该误差属于可接受的范围内。

对于内存存储引擎，stat 操作的步骤如下：

(1) 注册存储引擎监听器，当键值操作执行时，更新相应 Region 的读次数和写次数。同时当 set、delete 操作执行时，将 Region 的 dirty 位置为 true。

(2) 当心跳任务启动时，开始执行 Region 统计操作。

(3) 遍历数据服务器中的所有 Region，并将 dirty 位为 true 的 Region 放入 dirtyList 中。如果 dirtyList 的长度为 0，则直接返回。

(4) 将 dirtyList 中所有 Region 的键值数量以及大小都清 0。

(5) 遍历内存中所有的键值对，对于每一个键值对，尝试在 dirtyList 中找到对应的 Region。如果 Region 不为空，那么将 Region 包含的键值数目加一，并且大小加上该键值对的大小。

(6) 将 dirtyList 中所有 Region 的 dirty 位设为 false，统计操作完成。并向主服务器通过心跳的方式发送统计信息。

而对于持久化存储引擎，stat 的操作步骤为：

(1) 注册存储引擎监听器，当键值操作执行时，更新相应 Region 的读次数和写次数。同时当 set、delete 操作执行时，将 Region 的 dirty 位置为 true。

(2) 当心跳任务启动时，开始执行 Region 统计操作。

(3) 遍历数据服务器中的所有 Region，并对所有 dirty 位为 true 的 Region，进行下列操作。

(4) 将 Region 统计信息中的键值数量设为数据文件中的键值数量，大小设为数据文件大小。（其中数据文件中的键值数量和数据文件大小在每次重建索引时进行统计）。

(5) 检查写缓存中的数据，对于正常的键值对，则将键值数量加一，键值大小加上键值对的大小；而对于需要删除的键值对，则将键值数量减一，并将键值大小减去键值对的大小。

(6) 将 Region 的 dirty 位设为 false。如果数据服务器仍有待处理的 Region，则转入(4)，否则退出。

通过数据服务器与主服务器之间定期的汇报机制，使得统计操作可以在系统较为空闲的时间进行后台处理。而客户端调用 stat 操作时，主服务器直接将上次心跳的结果返回即可，而无需涉及数据服务器参加运算。不过该机制也会引入统计机制的一些误差，统计结果有一定的延迟性，另外对于持久化存储引擎写缓存中的数据，可能会出现重复统计的情况。

4.4 负载均衡

为平衡每个数据服务器的负载，提高数据服务器的总体利用率，系统提供了两种的负载均衡机制（简单均衡策略和高级均衡策略），用户可根据需求以及硬件配置状况灵活选择。

4.4.1自动路由

由于系统中的 Region 被分散到不同的数据服务器中，因此应用程序使用客户端访问集群时，客户端应自动根据所访问的键值对，连接到对应的数据服务器。这一过程被称为自动路由，具体过程如下：

(1) 客户端检查本地是否存在 Region 表，如果有直接转到(3)。

(2) 客户端根据用户指定的主服务器地址（可以为多个）尝试连接主服务器，并且请求最新的 Region 表。

(3) 根据键查找 Region 表，取得对应的数据服务器地址。

(4) 连接数据服务器，并发送相应的操作请求。

(5) 收到回复后，检查消息的返回值。如果返回值为“Invalid_Key”，并且没有重试过，则转到(2)，否则退出。

对于数据服务器，如果某个客户端所请求的键值对不属于该数据服务器时，数据服务器会返回值为“Invalid_Key”的消息。而客户端收到该消息后，发现本地的 Region 表已经过期，将向主服务器请求更新 Region 表后重新连接到新的数据服务器。理论上客户端重试一次之后将连接到正确的数据服务器，但是为了避免当系统的 Region 表出现故障时客户端无限重试的情况，系统要求客户端必须最多只能重试一次，否则将直接向调用者返回错误信息。

4.4.2 Region 分配

当主服务器中的未分配 Region 集合非空时， Region 分配任务会将集合中的 Region 分配到某些数据服务器中。通常有如下几种情况会导致主服务器中的未分配 Region 集合非空：主服务器刚启动、数据服务器退出或某个数据服务器的 Region 负载过多，以至于被 Region 卸载任务所卸载。

简单均衡策略的目的是将所有的 Region 按数量平均分配给数据服务器，以保证每个数据服务器中的 Region 数量基本相同。为了分配 Region，简单策略会首先将所有的数据服务器按 Region 数量升序排序。之后，依次向数据服务器中分配 Region，直到其数量达到所有数据服务器中 Region 数量的最大值。如果未分配的 Region 还有剩余，则逐个依次向每个数据服务器分配 Region，直到所有的 Region 被分配完成即可。

而高级均衡策略的目的是将所有的 Region 按照其负载量以及每个数据服务器的负载能力进行分配。Region 负载量需要考虑 Region 的大小、读次数和写次数，数据服务器负载能力则需要考虑空闲内存、总内存、CPU 使用率以及权值。另外为了叙述方便，定义符号 $\mathrm{diff}(A_i) = A_i * \mathrm{n}/\sum_1^n A_k$，即 Ai 与 A_1-A_n 的平均值的比值，系统用该比值来衡量系统的某个 Region 或数据服务器的负载量。高级均衡策略中 Region 分配的详细计算步骤如下：

(1) 计算每个 Region 的负载量，计算方法为 $\mathrm{Load}(R_i) = (2 * diff(\mathrm{RegionSize}_i) + diff(ReadCount_i) + diff(WriteCount_i))/4$。由于 RegionSize 对 Region 负载的影响较大，因此将其权值设为 2。

(2) 计算每个数据服务器的负载因子，计算公式为 $\mathrm{Factor}(S_i) = (\mathrm{diff}(MemoryFree_i) + \mathrm{diff}(MemoryTotal_i) + diff(CpuUsage_i)^{-1}) * Weight_i/3$。

(3) 计算每个数据服务器已分配的 Region 容量，计算公式为 $\mathrm{Capacity}(S_i) = \sum_1^n Load(R_k)/Factor(S_i)$。

(4) 将数据服务器按照容量升序排序，并依次向数据服务器中添加 Region，同时将 $\mathrm{Capacity}(S_i)$加上 $\mathrm{Load}(R_i)/\mathrm{Factor}(S_i)$，直至当前数据服务器的负载超过所有数据服务器的最大负载。

(5) 如果 Region 还有剩余，则逐个依次向每个数据服务器中分配 Region，直到所有的 Region 被分配完。

根据计算过程可以看出，高级的系统策略基于如下考虑：每个 Region 的负载(由大小、读次数和写次数决定)，每个数据服务器的能力（由空闲内存、总内存、CPU 使用情况以及用户指定的加权因子决定），以及对于同一个 Region，放到不同的数据服务器上，对数据服务器带来的负载也不同，例如放到性能强大的数据服务器上可能占用的资源比例较小，而放到性能较弱的数据服务器上则占用的比例较大。

当主服务器的 Region 分配任务计算出每个 Region 的目标数据服务器后，会向对应的数据服务器发送 Region 加载请求。之后数据服务器会根据请求的内容，加载对应的 Region，并返回操作结果。对于内存存储引擎和持久化存储引擎，有不同的加载过程。

内存存储引擎直接根据 Region 加载请求的 Id，找到 Region 的存放目录，并且将最新的日志文件载入内存即可。同时在载入的过程中，会检查内存的使用情况，当内存已满时置换出相应的键值对。

持久化存储引擎找到 Region 的存放目录之后，会按照时间倒序依次尝试加载数据文件，如果数据文件加载成功，则加载相应的日志文件。在加载数据文件的过程中，持久化存储引擎会对其进行遍历，并建立索引。如果索引建立失败，则说明数据文件在生成过程中有错误发生，持久化存储引擎则会尝试加载前一个数据文件。

4.4.3Region 卸载

Region 卸载主要发生在某个数据服务器的 Region 负载远超过其他数据服务器的负载的情况。系统根据某个数据服务器的负载量与数据服务器的最小负载量比值进行判断，如果该比值超过了用户指定的阈值，则需要对该数据服务器中的某些 Region 进行卸载。

简单均衡策略直接根据每个数据服务器的 Region 数量进行计算。如果某个数据服务器的 Region 数量与数据服务器 Region 数量最小值的比值超过了用户指定的阈值，则系统会随机选择数据服务器中的某些 Region 进行卸载，直至 Region 数量小于所有数据服务器 Region 数量的平均值。

复杂均衡策略则按照章节 4.4.2Region 分配描述的数据服务器容量 Capacity(S_i)的计算方法。如果某个数据服务器的容量与数据服务器中的最少容量比值超过了用户指定的阈值，则系统会随机选择数据服务器中的某些 Region 进行卸载，直至容量少于所有数据服务器容量的平均值。

主服务器中的 Region 卸载任务选择要卸载的 Region 后，会向对应的数据服务器发送 Region 卸载请求。之后，数据服务器会根据收到的请求，对 Region 进行卸载，并向主服务器报告结果。如果 Region 卸载成功，则该 Region 将被主服务器放在未分配 Region 集合中，等待下一次 Region 分配任务启动时进行分配。

数据服务器中 Region 的卸载操作比较简单，只需要关闭相应的日志文件，从缓存中清除该 Region 所包含的数据，并将该 Region 从 Region 集合中删除即可。日志文件被关闭时，HDFS 会将内存中的数据写入磁盘中，如果日志文件不能被正常关闭，则可能出现日志文件末尾数据丢失的情况。

另外，由于 Region 的卸载计算比较耗时，并且大部分时间内没有需要卸载的 Region，因此为节约主服务器的计算资源，最好将 Region 卸载任务的间隔时间设置的较长。

4.4.4Region 拆分

Region 拆分操作发生在当某个 Region 的大小超过了用户设定的阈值时，Region 的默认最

大值为 1GB。如图表 4-4 所示，Region 拆分操作将某个 Region 拆分成两个 Region，并且拆分后的两个 Region 所包含的键值对大小基本相同。对于 Region 的拆分操作，不区分简单策略和高级策略，都是通过大小进行判断。

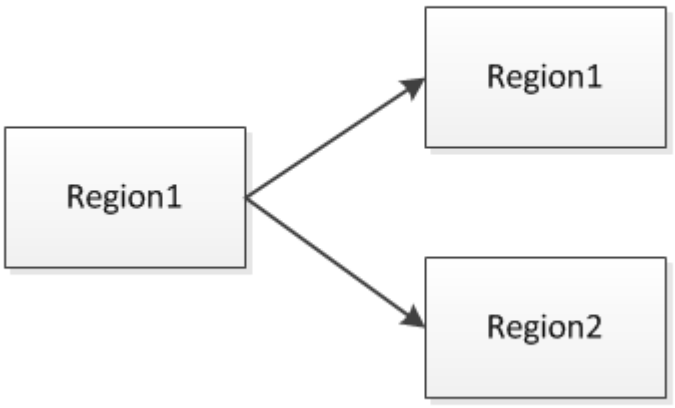

图表 4-4 Region 拆分示例图

主服务器中的 Region 拆分任务线程会定期遍历系统中的 Region，如果发现某个 Region 的大小超过了用户指定的阈值，便会生成新的 Region Id，并向相应的数据服务器发送 Region 拆分的请求。Region Id 采用递增序列的方式产生，并且当前值保存在 ZooKeeper 中。

当数据服务器收到 Region 拆分请求时，便会对指定的 Region 进行拆分操作，并向主服务器报告拆分结果。对于内存存储引擎和持久化存储引擎，有不同的拆分方式。

对于内存存储引擎，Region 拆分的步骤如下：

(1) 遍历内存中的所有键值对，并将属于将要拆分 Region 中的键值对放到链表中，同时统计这些键值对的大小。

(2) 遍历链表中的键值对，并同时累加键值对的大小，直至大小超过 Region 键值对的总大小的一半，同时记录下键的结束位置。则新 Region 的开始键为该结束键加一，结束键为老 Region 的结束键，而老 Region 的结束键设为该结束键。

(3) 为新、老 Region 分别创建日志文件，并且遍历老的日志文件，将记录项分别写入到新、老 Region 的日志文件中。

内存存储引擎的 Region 拆分操作主要计算出新老 Region 的开始结束键，以及将日志文件进行分割，而对内存中的键值对没有更改。

而对于持久化存储引擎，Region 拆分的步骤如下：

(1) 检查当前是否有任务线程正在运行，如果有，则直接退出；否则启动 Region 拆分任务线程。

(2) 分别创建新老 Region 的临时数据文件，并且都置于老 Region 的目录下。老 Region 文件的命名为“$timestamp”，新 Region 文件的命名为“$timestamp-new”，其中“$timestamp”

为当前时间戳。

(3) 遍历写缓存并检查老 Region 的数据文件的大小，统计出所有键值对的大小。

(4) 遍历写缓存和老 Region 的数据文件，按照大小平均的方式分别写入到新老 Region 的临时数据文件，同时记录下二者的边界键。

(5) 分别遍历新老 Region 的临时文件，并建立索引。

(6) 索引建立无误后，将新老 Region 的数据文件命名为“$regionid-$timestamp.data”，其中“$regionid”为 Region 的 Id，并将新 Region 的数据文件移动到新 Region 的目录下。之后分别为新老 Region 建立名为“$regionid-$timestamp.log”的日志文件。

(7) 最后将新 Region 的开始键设为边界键加一，结束键设为老 Region 的结束键，而老 Region 的结束键设为边界键。

在持久化存储引擎的 Region 拆分操作过程中，如果有错误发生，那么临时数据文件将不会被命名为合法的数据文件，并且将在一段时间之后被主服务器的垃圾回收线程所删除。

在系统的启动过程中，如果主服务器没有发现任何检查点文件或日志文件（通常是新系统启动），则会默认创建一个 Region 并包括所有的键值对。在系统的运行过程中，该 Region 会被逐渐拆分，并均衡到系统中其他的数据服务器中。

装

4.4.5 Region 合并

Region 合并操作发生在某两个相邻 Region 所含有的键值对的总大小小于用户设定的 Region 最大值的一半时。如图表 4-5 所示，Region 合并操作将两个相邻的 Region 为一个新的 Region。所谓相邻 Region，是一个 Region 的开始键应为另一个 Region 的结束键加一，只有两个 Region 相邻，才能进行合并。

订

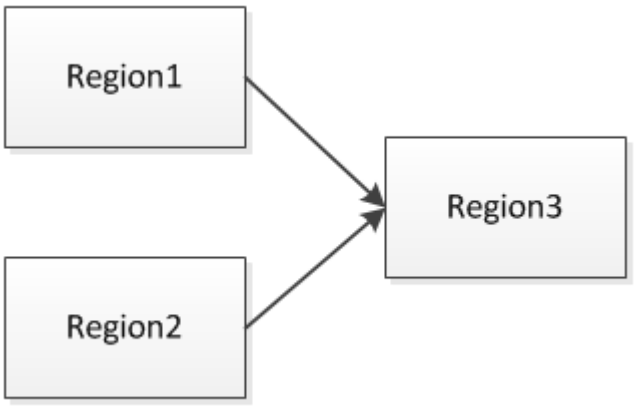

图表 4-5 Region 合并示例图

线

主服务器中的 Region 合并任务线程会定期的对数据服务器的 Region 进行遍历，并依次检查两个相邻的 Region 是否可以合并。由于数据服务器中的 Region 以有序集合的方式存储，因此只需对 Region 进行顺序检查即可。如果两个 Region 可以合并，那么主服务器会生成新的 Region Id，并向数据服务器发送合并 Region 请求。

当数据服务器收到 Region 合并请求时，会进行 Region 合并操作，并将合并结果报告给主服务器。

对于内存存储引擎，Region 合并的操作步骤如下：

(1) 创建新的 Region 对象，其键范围包括了要合并的两个 Region 的键范围，同时统计信息为两个 Region 统计信息的和。

(2) 为新的 Region 创建日志文件，并且遍历待合并的两个 Region 的日志文件，按照顺序添加到新的日志文件当中。

(3) 从数据存储引擎中将原有的两个 Region 删除，并添加新的 Region。

而对于持久存储引擎，Region 合并的操作步骤如下：

(1) 检查系统中是否有任务线程正在执行，如果有，则退出；否则启动 Region 合并线程。

(2) 为新的 Region 创建名为“$timestamp”的临时数据文件，其中“$timestamp”为当前时间戳。

(3) 将待合并的两个 Region 的写缓存和数据文件按顺序分别写入到 Region 的临时数据文件中，类似于两次写缓存提交操作。

(4) 遍历临时数据文件，并建立索引。

(5) 索引建立无误后，将临时数据文件重命名为“$regionid-$timestamp.data”，其中“$regionid”为新 Region 的 ID，并为新 Region 产生日志文件。

为避免 Region 合并失败时的影响，系统的 Region 合并操作将产生一个全新的 Region，而并非在待合并的 Region 上进行更新。

4.5 垃圾回收

由于系统运行过程中可能由于某些失败操作产生一些垃圾文件，并且会有过期的检查点文件或数据文件，因此主服务器会定期执行垃圾回收任务，对文件系统进行清理。

4.5.1 主服务器目录

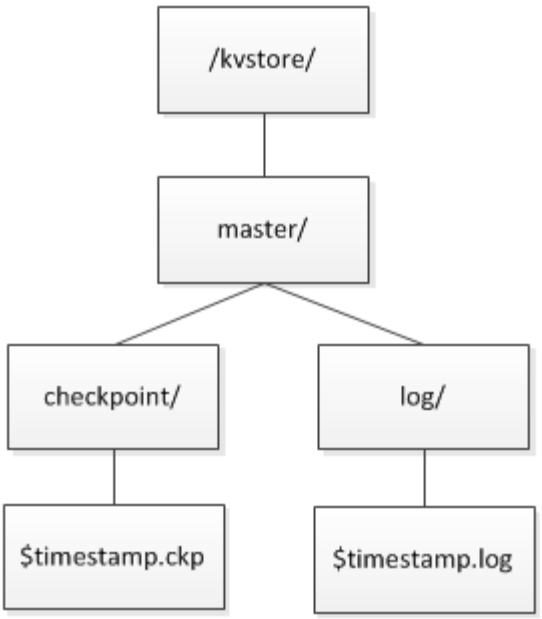

图表 4-6 主服务器目录结构图

图表 4-6 描述了主服务器的目录结构。检查点文件位于“/kvstore/master/checkpoint/”，并且命名格式为“$timestamp.ckp”，日志文件位于“/kvstore/master/log/”，并且命名格式为“$timestamp.log”，其中“$timestamp”为文件创建时的系统时间戳。

主服务的检查点目录和日志目录中只应当保存检查点文件、日志文件以及系统在生成检查点失败时产生的临时文件。用户可以分别指定检查点文件和临时文件保存的时间。

具体的检查步骤如下，对于检查点目录和日志目录下的每一个文件，执行如下操作：

(1) 检查文件命名规则，如果属于检查点文件或日志文件，转到(2)，否则转到(3)

(2) 从文件名中解析出文件的创建时间，并于当前时间比较，如果差值大于检查点文件的保存时间，则将其删除。

(3) 通过 HDFS 获得临时文件的创建时间，并于当前时间比较，如果差值大于临时文件的保存时间，则将其删除。

4.5.2数据服务器目录

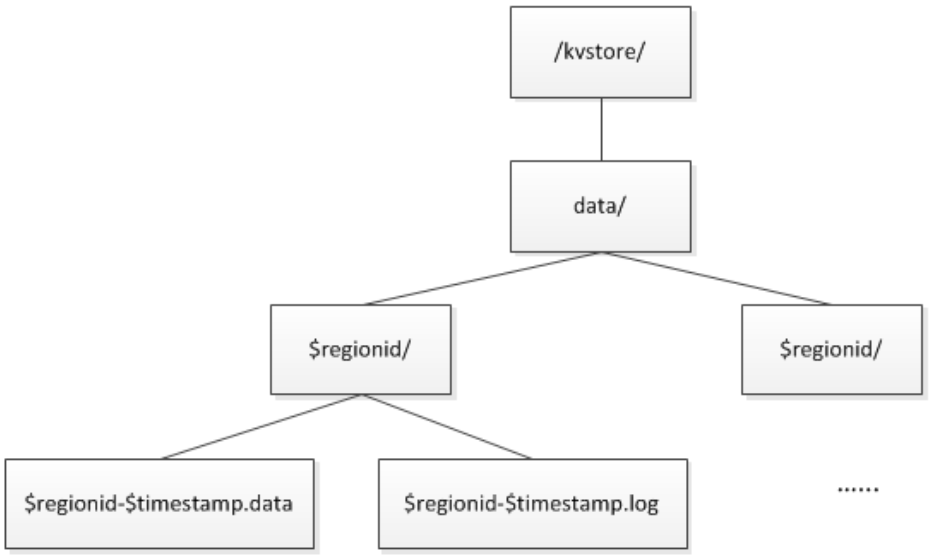

图表 4-7 数据服务器目录结构图

图表 4-7 描述了数据服务器的目录结构。数据服务器中的 Region 目录为“/kvstore/data/$regionid”中，其中“$regionid”为 Region 的 ID 值。在内存存储引擎中，该目录只会存放命名格式为“$regionid-$timestamp.log”的日志文件，而在持久存储引擎中，该目录下会存放命名格式为“$regionid-$timestamp.data”的数据文件、日志文件以及由 Region 操作失败时产生的临时文件，其中“$timestamp”为文件创建时的系统时间戳。用户可以分别指定 Region 数据文件和临时文件的保存时间。

具体的检查步骤如下，对于“/kvstore/data/”下的所有子目录，执行如下操作：

(1) 如果当前 Region 目录为空，并且主服务器的 Region 表中不包含该 Region，那么删除

该目录，否则转到(2)。

(2) 列出当前 Region 目录中的所有文件，并遍历每个文件。

(3) 检查文件命名规则，如果属于数据文件，则放入数据文件集合中；如果属于日志文件，则放入日志文件集合中，并转到(5)。

(4) 通过 HDFS 获得临时文件的创建时间，并于当前时间比较，如果间隔大于临时文件的保存时间，则将其删除。

(5) 检查目录中是否还有文件存在，如果有，那么选择下一个文件，并转到(3)。

(6) 将数据文件集合和日志文件集合按照文件名升序排序，即先创建的文件在前，后创建的文件在后。

(7) 分别对于数据文件集合和日志文件集合的前 n-1 个文件，如果文件名中的时间戳与当前时间的差值大于 Region 数据文件的保存时间，就将其删除，否则退出循环。其中 n 为数据文件集合和日志文件集合的大小。

第(7)步的目的是因为 Region 的数据文件不是以固定的时间间隔产生，而是取决于 Region 数据的写入量。因此通过上述步骤可以避免当某个 Region 长时间没有新的数据文件产生时系统将所有的 Region 数据文件全部删除的情况。

装

4.6 系统配置

为提高系统的灵活性与可配置性，系统尽可能的将所有可能变化的参数都从配置文件读取。系统的配置文件采用 Java 属性文件的格式，即每行对应了用等号分割的键值对。

订

系统中通常有两个配置文件，一个名为“kvstore.default.properties”，其中定义了系统中所有可能出现的配置信息，并提供了相应的默认参数和注释信息。而另一个名为“kvstore.properties”的配置文件需要用户提供，并且其中的配置信息将覆盖“kvstore.default.properties”文件中的配置信息。

线

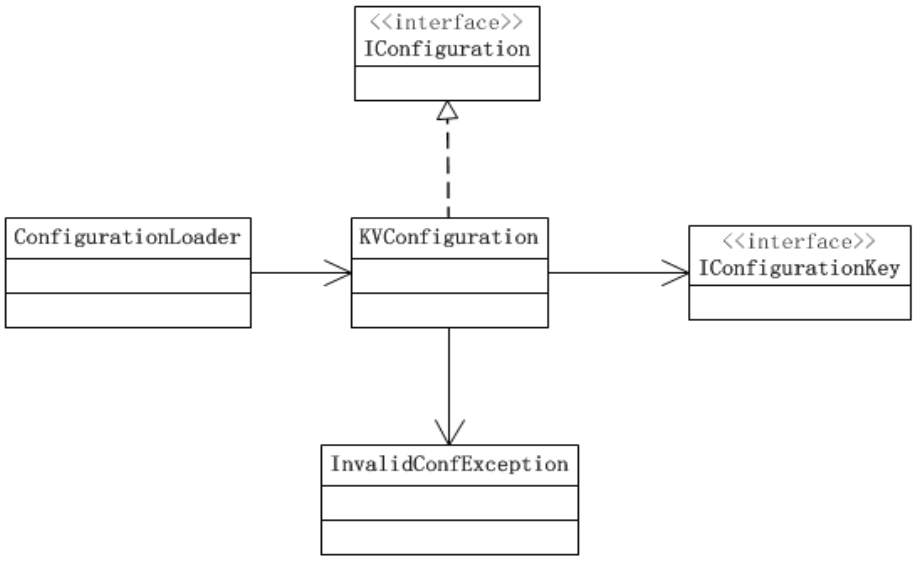

图表 4-8 系统配置类图

图表 4-8 描述了系统配置相关的主要类图。其中 IConfiguration 定义了配置类的接口，如根据键取得相应值。同时，IConfiguration 的实现类应负责值的单位转换，如将配置文件中的天数转换为毫秒数。IConfiguration 的调用者会在调用时进行检查，如果用户提供的参数值有误，那么将抛出 InvalidConfException 异常。

ConfigurationLoader 负责对配置文件的加载。在系统启动过程中，ConfigurationLoader 将首先加载“kvstore.default.properties”文件，之后将尝试加载“kvstore.properties”文件，如果该文件存在，那么该文件中的键值对将覆盖之前读取的配置信息。

系统的配置文件中包含了如主服务器地址、数据服务器地址、HDFS 地址、ZooKeeper 地址、数据服务器存储引擎、内存置换算法、负载均衡策略、Region 大小等内容，具体可参考系统提供的“kvstore.default.properties”中的配置项以及相应的注释。

4.7 系统监控

4.7.1 监控模块

系统中集成了 JavaSimon 和 JavaMelody 两款开源的 Java 性能监控系统。JavaSimon 可用于记录系统中关键操作的执行时间，并以图表的方式展现；而 JavaMolody 可监控 Java 虚拟机的运行情况，例如内存使用、异常错误信息、线程情况等。同时系统中内置了 tomcat 服务器，当开启监控功能时，tomcat 服务器也会随主服务器或数据服务器启动时启动。

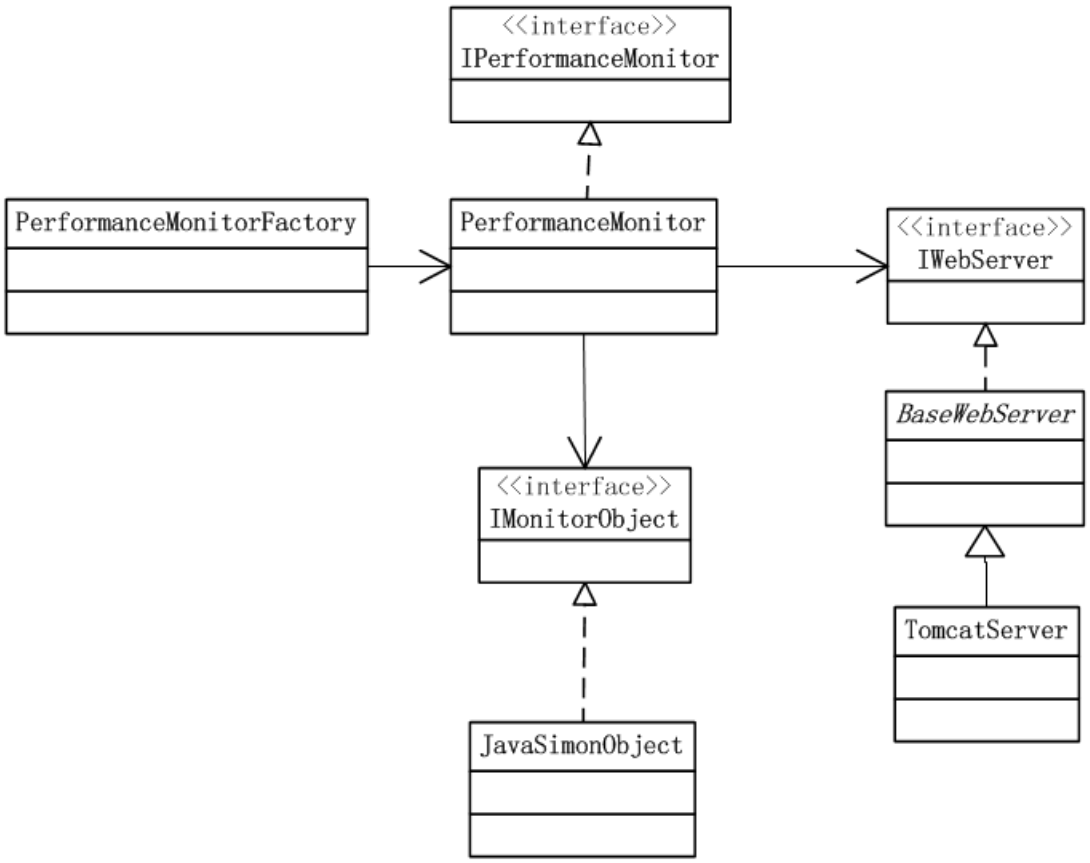

图表 4-9 系统监控模块类图

图表 4-9 描述了系统监控模块的主要类图。

(1) IPerformanceMonitor

IPerformanceMonitor 定义了系统性能监控模块的主要接口，例如根据字符串键获得对应的监控对象，以及启动、停止等。另外 WebServer 也由 IPerformanceMonitor 管理。

(2) IWebServer

IWebServer 封装了 web 服务器的接口，并且系统中提供了基于 Tomcat7 的 TomcatServer 实现。

(3) IMonitorObject

IMonitorObject 对应了需要监控执行时间的一个代码段。其中包含了开始和结束方法。

4.7.2 使用方法

对于主服务器，系统只使用 JavaMolody 监视机器的内存、CPU、线程等情况，而对于数据服务器，除了监视上述内容之外，系统还对 get、set 等键值操作以及拆分、合并等 Region 操作的执行时间通过 JavaSimon 进行监控。对于需要监控操作时间的代码段，需要在代码开始前，通过 PerformanceMonitor 拿到相应的 IMonitorObject，并且调用开始方法；在代码结束之后，再调用 IMonitorObject 的结束方法。

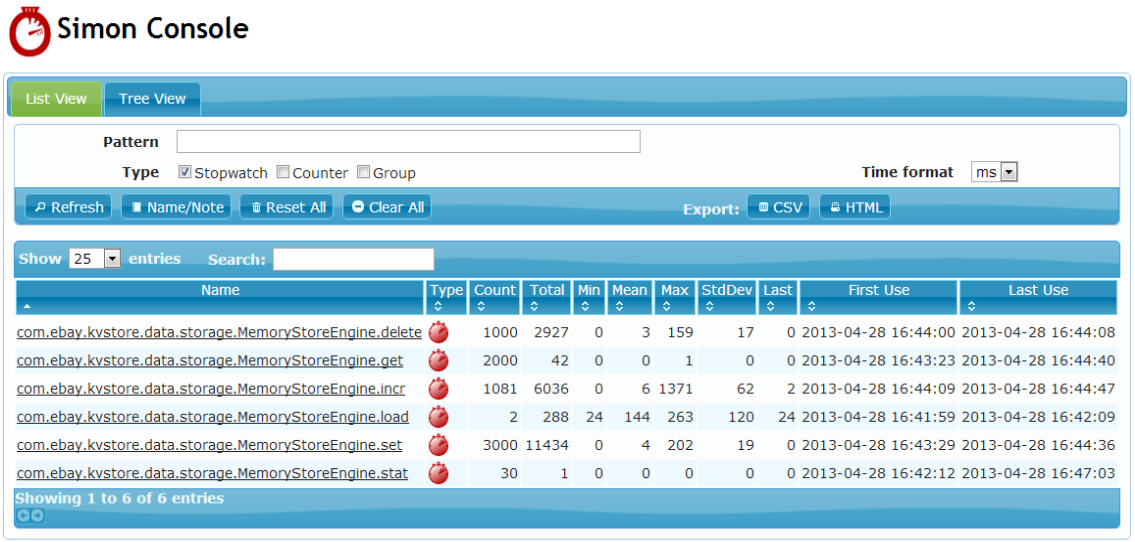

图表 4-10 系统操作时间统计结果示例图

图表 4-10 为数据服务器操作时间的统计结果页面。用户可通过地址“http://ip:port/stat”访问该页面，其中ip为数据服务器的地址，port为数据服务器的tomcat监听端口，默认为8080。从结果页面中可以看到每个关键操作的执行次数、总时间、最小时间、平均时间等数据，并且可将数据导出为 CVS 或 HTML 格式。

装 订 线

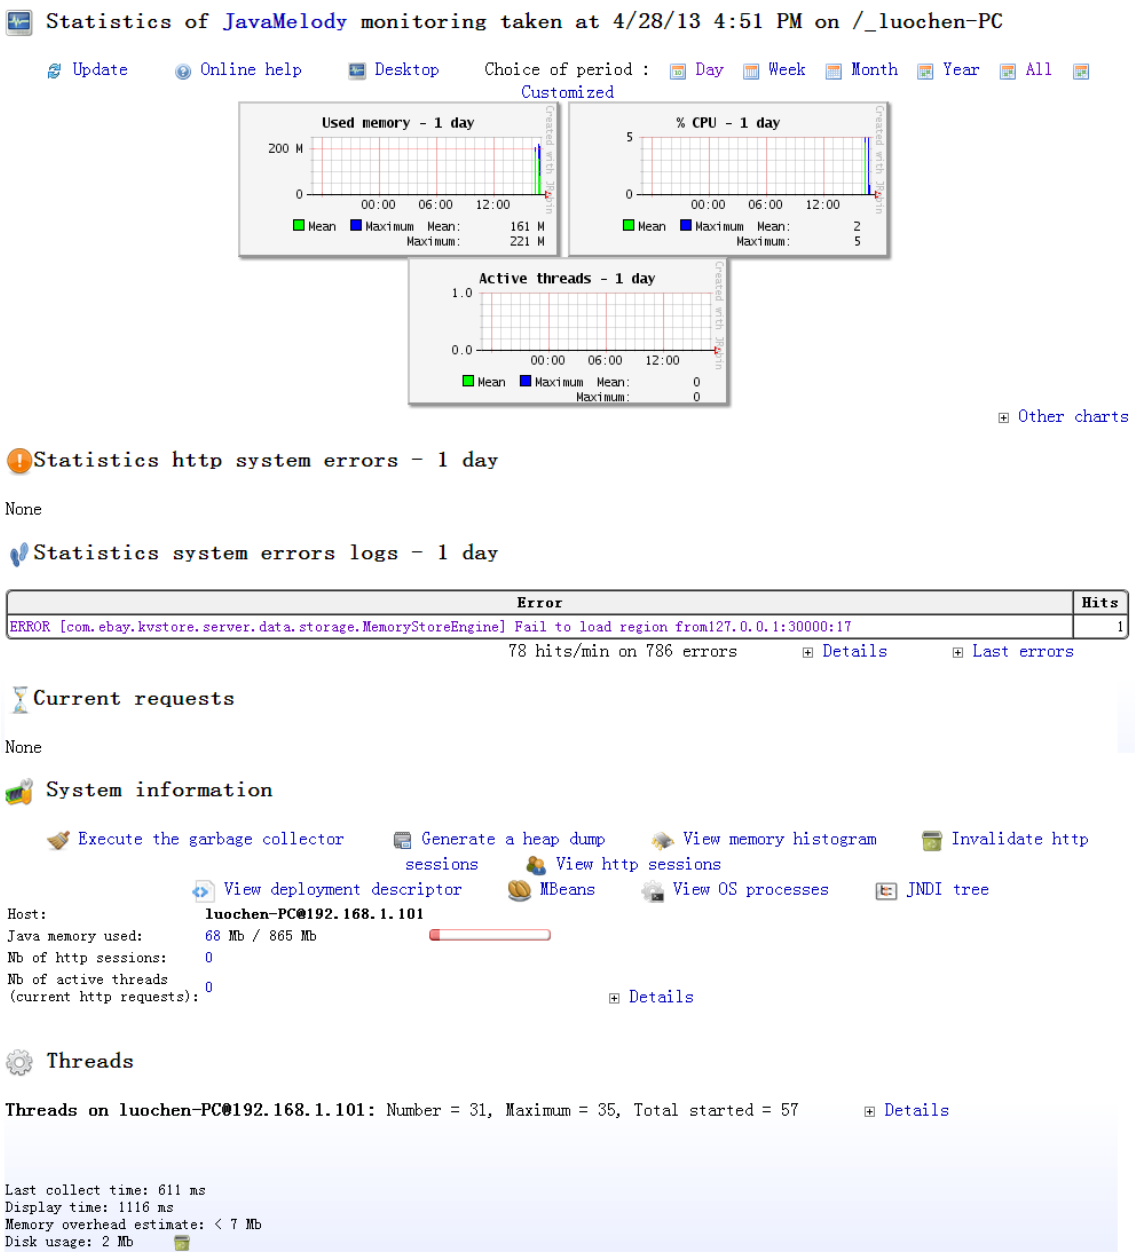

图表 4-11 系统性能监控结果示例图

图表 4-11 为系统性能监控的页面。用户可通过地址 http://ip:port/monitoring 访问，其中 ip 为服务器地址，port 为主服务器或数据服务器中 tomcat 默认监听的端口，主服务器为 8000，数据服务器为 8080。在该页面中，用户可看到系统运行期间的内存、CPU 使用情况，错误日志，当前线程情况以及操作系统的详细信息等。

通过上述的监控机制，允许开发人员在系统运营时随时监控系统的运营状态，并发现潜在问题。但由于两个监控程序同样需要消耗一定的服务器资源，因此开发人员可根据自身需求决定是否使用该监控功能。

5 性能数据

5.1 测试环境

由于环境限制，我们只在两台机器搭建的小型集群中对系统进行了性能测试。其中机器 A 的硬件配置为 2.8GHZ 四核 CPU，4G DDR3 内存和 500G 机械硬盘，机器 B 的硬件配置为 2.4G 四核 CPU，4G DDR3 内存和 500G 机械硬盘。两台机器通过百兆以太网相连。

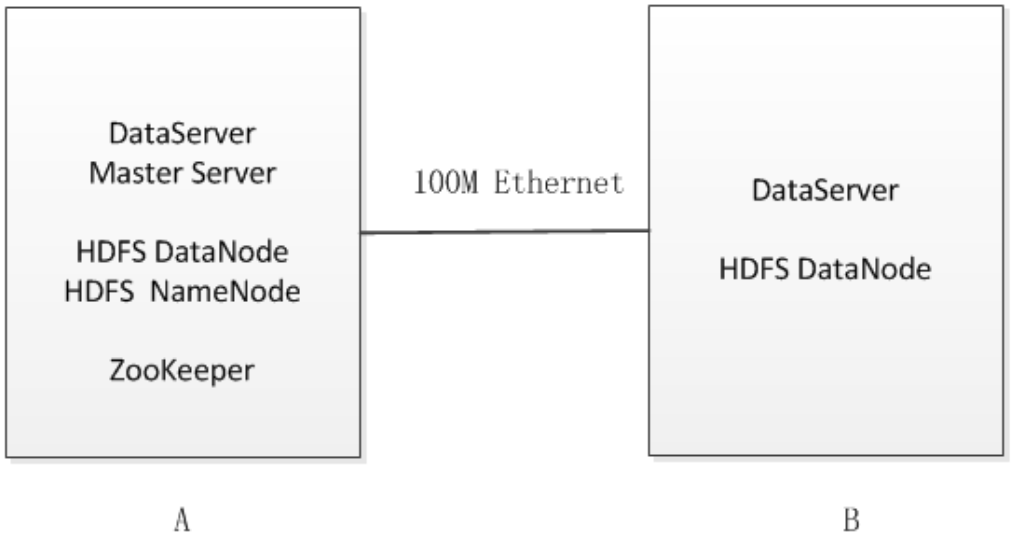

图表 5-1 测试环境示例图

如图表 5-1 所示，ZooKeeper 被安装在机器 A 中。HDFS 的命名节点也被安装在机器 A 中，而 HDFS 的数据节点被同时安装在 A 和 B 中，文件的块大小为 64MB，块的副本数量为 2。另外系统全部采用默认配置，并且主服务器安装在 A 中，数据服务器分别安装在 A 和 B 中。

5.2 测试方法

我们采用通过客户端调用的方式对系统的性能进行测试。在测试程序中，一定数量的线程并发的向服务器发送请求，以测试系统的性能。请求的键值对随机生成，大小由 10 字节到 10KB 不等。测试的内容包括内存存储引擎与持久化存储引擎的读操作性能（get）、写操作性能（incr、delete、set）以及随机操作性能。同时，对于持久化存储引擎，还需要观察写缓存提交、Region 拆分、合并等操作对服务器响应时间的影响。

在测试过程中，测试程序将会以同步的方式进行客户端调用，同时记录下每次调用的时间，并对测试结果进行汇总。

5.3 性能结果

5.3.1 内存存储引擎

TPS / 操作	10	20	30	40	50
读	0.067/0.144/1.3(ms)	0.063/0.21/2.8	0.066/0.152/2.4	0.048/0.111/2.091	0.026/0.174/2.5
写	0.032/0.058/0.821	0.031/0.049/0.463	0.026/0.046/0.31	0.02/0.048/0.838	0.023/0.046/1.82
随机	0.027/0.11/1.0	0.031/0.143/1.868	0.029/0.45/2.287	0.015/0.109/1.988	0.028/0.098/1.018

表格 5-1 内存存储引擎服务器操作时间表

TPS / 操作	10	20	30	40	50
写	0.7/5.43/27.7(ms)	0.512/8.68/92.5	0.327/9.51/62.7	0.851/12/73.4	0.621/22.6/124
读	0.565/4.2/34.9	0.369/7.27/49	0.336/6.7/65.6	0.498/5.97/59.2	0.341/7.6/67.7
随机	0.4/5.06/42.2	0.392/8.49/92.2	0.304/11.6/87	0.302/9.16/82.2	0.509/14.4/83.7

表格 5-2 内存存储引擎客户端调用时间表

表格中的数据值分别为相应条件下的最小值、平均值以及最大值。表格 5-1 为内存存储引擎在不同的操作以及每秒访问次数下的操作时间。从表格中可以看出，操作时间的数量级都为毫秒级。由于内存存储引擎的读、写以及随机操作都是直接操作内存以及顺序的写入操作日志文件，因此每次操作的响应时间也较短。

而表格 5-2 为同样的操作情况下，客户端程序从调用开始到结束的时间。从表格可以看出，该时间要比表格 5-1 中描述的时间长很多。由于网络连接、传输以及高并发情况下多线程之间的竞争都需要占用时间，因此导致了客户端程序观察到的操作时间要大于服务器端记录的时间。同时，如图表 5-2 所示，随着并发访问量的提高，操作所需的时间也随之提高。

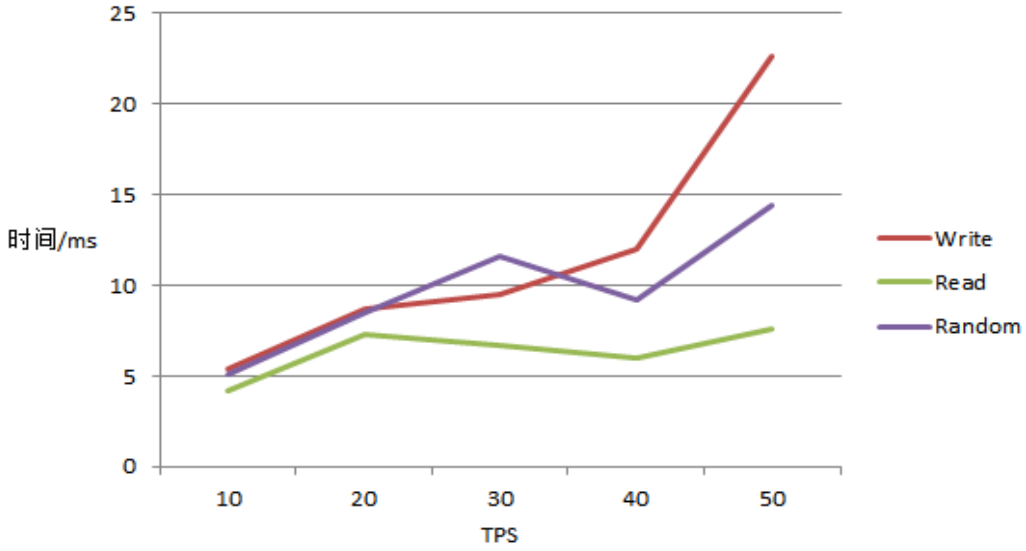

图表 5-2 内存储存引擎客户端调用时间图

5.3.2持久化存储引擎

TPS / 操作	10	20	30	40	50
写	0.028/0.12/1.18(ms)	0.062/0.194/1.981	0.045/0.151/1.125	0.022/0.141/1.455	0.041/0.146/1.043
读	0.071/3.96/45.114	0.036/2.629/54.3	0.032/3.394/45.876	0.029/3.4/48.23	0.022/5.82/49.73
随机	0.028/2.79/16.6	0.038/2.19/31.1	0.037/2.95/22.6	0.017/3.1/52.9	0.032/4.34/62.2

表格 5-3 持久化存储引擎服务器操作时间表

TPS / 操作	10	20	30	40	50
写	0.322/5.14/24.5ms	0.488/15.3/125	0.323/17.3/111	0.273/24.2/215	0.416/35/219.4
读	0.58/15.36/89	0.297/12.59/104	0.511/19.28/106.3	0.238/18.01/86.4	0.346/20.6/92
随机	0.273/8.96/47.2	0.314/14.6/87.8	0.314/16.42/295	0.278/20.7/282	0.444/30.4/327

表格 5-4 持久化存储引擎客户端调用时间表

与内存存储引擎的测试方法类似，表格 5-3 给出了持久化存储引擎在不同操作以及不同的每秒访问次数下服务器相应的操作时间。操作时间同样以毫秒级为单位。不过从表格中可以看出，读操作所需的时间却通常大于写操作，这是因为写操作是直接的内存操作，而读操作在检查布隆过滤器后有可能进行文件读取操作，因而测试结果也与系统的实现一致。

表格 5-4 给出了在同样条件下，客户端完成相应的操作所需的时间。与内存存储引擎的测试结果类似，客户端完成整个操作所需的时间会大于服务器键值操作的时间，并且随着并发访问量的提高而提高（如所示）。

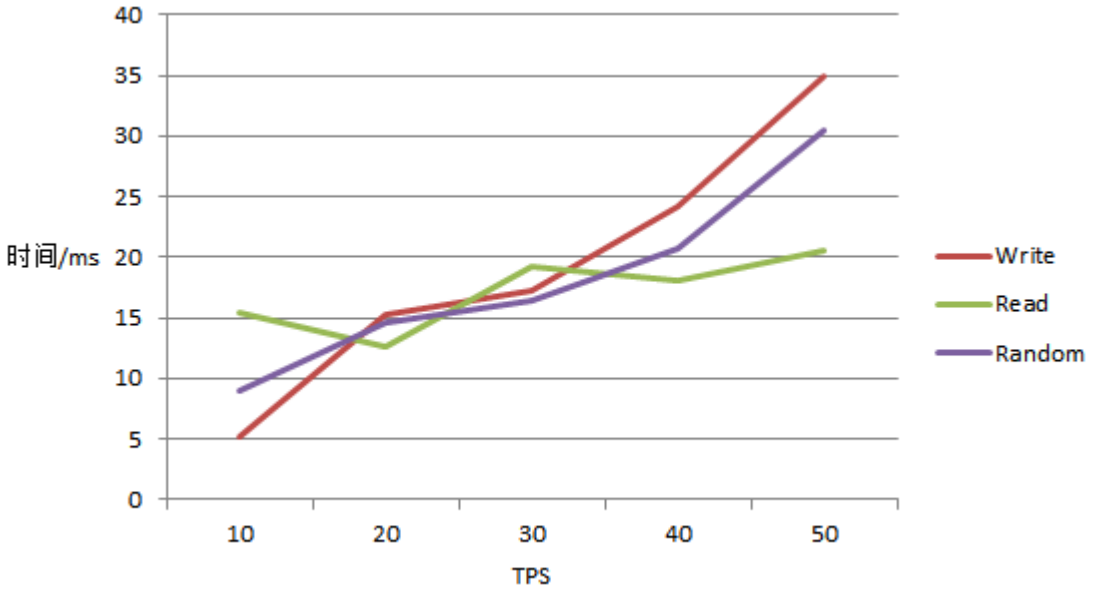

图表 5-3 持久化存储引擎客户端调用时间图

从测试结果可以看出，数据服务器中键值操作的效率很高。但由于网络连接与传输、多线程竞争以及其他的开销，导致服务器的请求响应时间仍有很大的优化余地。因此下一步的工作将包括对数据服务器的多线程并发、代码结构以及网络连接方面的优化，以降低系统的响应时间。

6 使用场景

基于键值的 NoSQL 数据存储系统在应用系统中通常被用作缓存系统，以减轻数据库或应用服务器的压力。同时也适用于存储业务逻辑较为简单的持久化数据，例如文档、多媒体数据等。但由于缺少事务支持，以及模型较为简单，基于键值的数据存储系统不适用于处理业务逻辑复杂的数据。

6.1 缓存系统

6.1.1 概述

为减轻数据库或应用服务器的压力，应用开发者通常会缓存某些计算的结果。而本系统非常适合用作缓存系统，其作为缓存系统具备的优点如下：

(1) 内存存储引擎具有较好的读写性能，同时当内存满时被置换出的某些键值对不会影响应用程序的运行。

(2) 通过指定键值对的存活时间，可使得键值对在某个固定时间之后失效，以达到更新缓存的目的。应用程序也可手动对缓存进行更新，但操作较为复杂。

(3) 系统对数据库服务器提供了故障恢复以及自动路由等功能，避免了当某台服务器失效时的缓存大面积失效问题。

(4) 集中式缓存相比于应用服务器的本地缓存命中率更高，只要当一台应用服务器被访问时，缓存便会产生。

通常在应用程序中，开发人员可将以下一些内容进行缓存：

(1) 数据库查询结果

开发人员可缓存数据库查询的结果，以减少数据库的访问压力。对于简单的数据库查询，例如主键查询，可以直接用记录的主键作为缓存键；而对于复杂的多表连接查询，可以将 SQL 语句与参数拼接为缓存键，进行缓存。

(2) Web 服务调用结果

目前大多数应用系统都采用 SOA 架构，即将不同的业务模块作为服务的方式进行部署和调用。因此应用程序可缓存 web 服务的调用结果，以减少应用服务器的压力，同时提高系统的响应速度。

(3) 序列化对象

MVC 是目前主流的应用程序架构。而其中的 M 对应了 Model，即通过一系列的计算得到的模型，并且被用于进行结果展示。开发人员可将序列化后的模型对象进行缓存，下次访问时直接进行缓存中反序列化即可，而无需再次进行复杂的计算操作。

(4) 动态页面

目前大多数应用程序都采用动态页面的方式进行展示，例如 jsp、php 等技术。对于某些较长时间不变的页面或部分页面，开发人员可将其进行缓存，以允许下次用户访问时不必重新进行渲染，极大的提高响应速度。

6.1.2 缓存模型

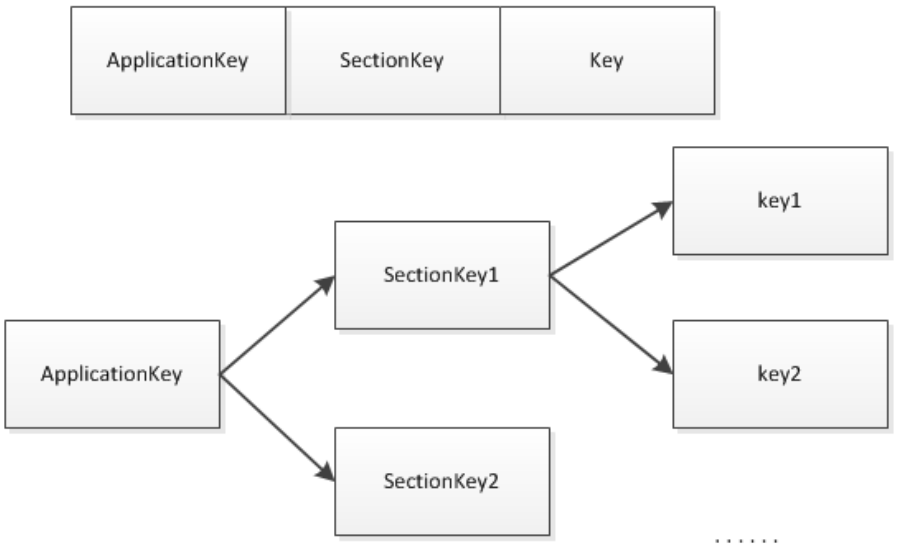

图表 6-1 缓存模型图

缓存系统可以使用图表 6-1 所示的存储模型，键通过 ApplicationKey、SectionKey 以及 Key 三者唯一生成，以对系统中的缓存数据键进行区别。另外键可以通过字节数组组合的方式进行生成。

(1) ApplicationKey

ApplicationKey 是唯一标识应用程序的键。由于本系统通常作为集中式的缓存系统运行，因此通过采用 ApplicationKey，可以避免不同应用程序之间缓存的冲突。如果某些缓存需要在多个应用程序间共享，只需将 ApplicationKey 设为相同即可。

(2) SectionKey

SectionKey 标识了某一个应用程序中的不同的缓存数据模块，例如可以是不同的 SQL 数据库表，或者 web 服务。通常一个应用程序中会有不同的缓存数据模块，而 SectionKey 可以避免模块间的冲突。

(3) Key

Key 是唯一表示应用程序某个缓存数据模块的唯一标识，例如数据库表的主键或者 web 服务调用的参数。

例如，假定名为“A”的应用程序中有名为“User”的数据库表，每个用户通过唯一的数字 ID 进行标识，并且键之间采用“:”进行组合。因此对于主键“100000”标识的用户，其在缓存中的键为“A：User：100000”。通过以上描述的数据模型，应用开发人员可对系统提供的客户端库程序进行进一步的封装，以适应不同的应用场景，方便使用。

6.2 持久化存储

除了用作缓存系统之外，用户同样可以使用本系统的持久化存储引擎来持久化存储某些数据。但是由于系统的键值模型较为简单，并且没有事务等特性的支持，因此较适合存储某

些数量大、访问频繁但是结构相对简单的数据，例如图片、多媒体文件对象、文档等数据。同样，由于应用程序可自己解释二进制数据的内容，因此也可存储序列化后的对象、JSON 对象以及其他自定义格式的二进制数据。

考虑一个简单的文档分享系统，用户可对文档进行编辑、分享以及查看等操作。由于本系统中文档为主要数据，由于包含格式信息，文档的大小可能会比较大（数 KB 到数 MB 不等），并且访问比较频繁。因此为减轻关系数据库的访问压力，应用程序可将文档数据作为键值对存放在本系统中，而其他的业务逻辑相关的数据如用户数据、用户文档关联数据等则可存储在关系数据库中。同样，应用程序也可使用章节 6.1 缓存系统描述的数据模型，以避免应用程序之间和模块之间的冲突。

7 相关工作

2000 年加州大学伯克利分校的 Eric Brewer 教授提出了著名的 CAP 理论[11] 奠定了分布式存储系统的基础。人们在设计分布式存储系统时，不再盲目追求三者，而是尝试为分区容忍性、数据一致性和可用性进行取舍或达到三者的平衡，学术界和工业界都出现了许多优秀的分布式存储系统。随着 Google 的 BigTable[7] 以及 Map Reduce[17] 等论文的发表，人们开始为集群的强大威力所惊叹，NoSQL 数据库也开始进入了蓬勃发展的年代，各大公司都逐渐公布了自己的 NoSQL 数据存储系统，例如高可用的键值数据库 Dynamo[6] ，面向地理范围分布的键值数据库 Pnuts[18] 。同时，许多开源的 NoSQL 数据库也随之产生，例如高性能的键值数据库 Redis，面向文档存储的 NoSQL 数据库 mongodb 等，并且被业界广泛使用。另外，学术界早先对分布式算法的研究也为分布式 NoSQL 数据库奠定了基础，其中 Paxos 算法[15] 、Gossip 协议[10] 等算法被广泛应用在分布式数据库中。NoSQL 数据库也从传统的 SQL 数据库的研究中借鉴了许多思想，如并发控制[3] 、数据备份与恢复以及事务控制等内容。

8 结论与展望

本课题基于前人在数据库及分布式系统领域所作的工作，设计并实现了一个基于键值的分布式 NoSQL 数据存储系统原型。通过最终的测试，证明了本系统的可用性以及负载均衡、自动故障恢复等方案的可行性。同时本文也以实例的方式讨论了本系统的使用场景，为系统的潜在用户提供了一些使用指南。但通过性能测试的结果发现，数据服务器在高并发的条件下仍有许多需要优化的地方，例如线程竞争、网络传输等内容，这也将是今后工作的重点。

回顾 NoSQL 数据存储系统的发展历程，人们现在已经逐渐意识到 NoSQL 与 SQL 并非替代关系，而应为互补关系，这点从 No 被看作是“Not Only”的缩写也可看出。随着软件系统规模以及数据规模的日益增大，系统的可伸缩性也逐渐的开始被架构师所重视。而 NoSQL 数据库的模型简单、易于扩展等优点，相信会被大规模应用系统的开发人员所重视。但与此同时，SQL 数据库由于功能强大、模型完整等优点，并且性能足以满足中小型应用的业务需求，因此也不会退出历史舞台。相信在未来的发展过程中，NoSQL 与 SQL 数据库将相互取长补短，共同发展，以更好的适应现实中的应用需求。

9 主要参考文献

[1] Silberschatz A, Korth H F, Sudarshan S. Database system concepts[M]. Hightstown: McGraw-Hill, 1997.

[2] Codd, E.F. (1970). "A Relational Model of Data for Large Shared Data banks". Communications 13 (6): 377–387. doi:10.1145/362384.362685

[3] Bernstein P A, Hadzilacos V, Goodman N. Concurrency control and recovery in database systems[M]. New York: Addison-wesley, 1987.

[4] Pritchett D. Base: An acid alternative[J]. Queue, 2008, 6(3): 48-55.

[5] Cattell R. Scalable SQL and NoSQL data stores[J]. ACM SIGMOD Record, 2011, 39(4): 12-27.

[6] DeCandia G, Hastorun D, Jampani M, et al. Dynamo: amazon's highly available key-value store[C]//ACM Symposium on Operating Systems Principles: Proceedings of twenty-first ACM SIGOPS symposium on Operating systems principles. 2007, 14(17): 205-220.

[7] Chang F, Dean J, Ghemawat S, et al. Bigtable: A distributed storage system for structured data[J]. ACM Transactions on Computer Systems (TOCS), 2008, 26(2): 4.

[8] Lakshman A, Malik P. Cassandra: a decentralized structured storage system[J]. ACM SIGOPS Operating Systems Review, 2010, 44(2): 35-40.

[9] Vogels W. Eventually consistent[J]. Communications of the ACM, 2009, 52(1): 40-44.

[10] Allavena A, Demers A, Hopcroft J E. Correctness of a gossip based membership protocol[C]//Proceedings of the twenty-fourth annual ACM symposium on Principles of distributed computing. ACM, 2005: 292-301.

[11] Brewer E. CAP twelve years later: How the[J]. Computer, 2012, 45(2): 23-29.

[12] Gilbert S, Lynch N. Brewer's conjecture and the feasibility of consistent, available, partition-tolerant web services[J]. ACM SIGACT News, 2002, 33(2): 51-59.

[13] Ghemawat S, Gobioff H, Leung S T. The Google file system[C]//ACM SIGOPS Operating Systems Review. ACM, 2003, 37(5): 29-43.

[14] Burrows M. The Chubby lock service for loosely-coupled distributed systems[C]//Proceedings of the 7th symposium on Operating systems design and implementation. USENIX Association, 2006: 335-350.

[15] Lamport L. Paxos made simple[J]. ACM SIGACT News, 2001, 32(4): 18-25.

[16] Bloom B H. Space/time trade-offs in hash coding with allowable errors[J]. Communications of the ACM, 1970, 13(7): 422-426.

[17] Dean J, Ghemawat S. MapReduce: simplified data processing on large clusters[J]. Communications of the ACM, 2008, 51(1): 107-113.

[18] Cooper B F, Ramakrishnan R, Srivastava U, et al. PNUTS: Yahoo!'s hosted data serving platform[J]. Proceedings of the VLDB Endowment, 2008, 1(2): 1277-1288.

装 订 线

10 谢辞

首先诚挚的感谢指导教师穆斌教授，穆斌教授在数据库领域的造诣颇深。在毕业设计过程中，穆斌教授的指导与建议为本课题的完成提供了很大帮助，同时也令我收益匪浅。

本论文的完成另外亦得感谢 eBay 上海研发中心的工程师 Tony Zhu 的大力协助。Tony Zhu 是我在 eBay 上海研发中心所参与实习生项目的导师，同样也在开发过程中为我提供了很多指导和帮助。Tony Zhu 也允许我参加 eBay 每周的数据库讨论会，在会上我也看到了 eBay 目前所面临的问题，以及大家讨论出的解决方案，也为本系统的实施方案带来了许多启发。

谨以此谢辞最后，我要向百忙之中抽时间对本文进行审阅的各位老师表示衷心的感谢。